

МОСКОВСКИЙ ФИЗИКО-ТЕХНИЧЕСКИЙ ИНСТИТУТ
(национальный исследовательский университет)
ФИЗТЕХ-ШКОЛА ПРИКЛАДНОЙ МАТЕМАТИКИ И ИНФОРМАТИКИ
КАФЕДРА ИНТЕЛЛЕКТУАЛЬНОГО АНАЛИЗА ДАННЫХ ВЦ РАН

Крейнин Матвей Вадимович

ФЛОУ МАТЧИНГ В ЗАДАЧАХ ТРАНСЛЯЦИИ КОМПЬЮТЕРНОЙ ТОМОГРАФИИ

09.04.01 — Информатика и вычислительная техника

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА МАГИСТРАНТА

Научный руководитель:

к.ф.-м.н. А. С. Грабовой

Москва — 2026

Аннотация

В работе исследуется задача порождающего моделирования условного распределения медицинских изображений: построение измеримого отображения $T : \mathbb{R}^d \rightarrow \mathbb{R}^d$, переводящего распределение нативных компьютерных томограмм π_N в распределение их контрастных аналогов π_C (и обратно). Формально требуется решить транспортную задачу $T_{\#}\pi_0 = \pi_1$ в $d = 512^2$ -мерном пространстве при наличии парных наблюдений $(\mathbf{x}_N, \mathbf{x}_C) \sim \gamma$, $\gamma \in \Pi(\pi_N, \pi_C)$.

Предлагается метод **Medical Flow Matching (MFM)** — условный флоу матчинг с линейным интерполянтом $\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1$. Минимизируется симуляционно-свободный функционал

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0,1], (\mathbf{x}_0, \mathbf{x}_1) \sim \gamma} [\|f_{\theta}(\mathbf{x}_t, t) - (\mathbf{x}_1 - \mathbf{x}_0)\|_2^2],$$

аппроксимирующий маргинальное поле скоростей u_t , порождающее перенос. Реализацией f_{θ} служит архитектура **TimeResNet** — U-Net с поблочной аффинной модуляцией синусоидального временного эмбединга и свёрточным модулем self-attention на боттлнеке. В отличие от диффузионных моделей, требующих $T \sim 10^2$ – 10^3 шагов денойзинга, при линейном интерполянте кинетическая энергия потока минимальна, кривизна траектории нулевая, и интегрирование ОДУ методом Эйлера за один шаг точно с точностью до аппроксимационной ошибки сети.

На отложенной выборке из 20 пациентов (9 372 среза) MFM достигает $\text{MAE} = 4.25$ HU, $\text{SSIM} = 0.994$ и $\text{PSNR} = 42.19$ дБ при времени инференса 0.125 с на срез, сокращая время в **354 раза** по сравнению с DDPM и в **7.1 раза** снижая MAE по сравнению со SMILE [1]. Из симметрии линейного интерполянта следует двунаправленность: единственная сеть f_{θ} реализует трансляцию в обе стороны без увеличения числа параметров. Прикладная значимость подтверждается тем, что nnUNet v2, обученный на синтезированных MFM нативных срезах, достигает $\text{Dice} = 0.926$ (95.9% от уровня 0.966 на реальных данных) в задаче сегментации аорты.

Ключевые слова: условный флоу матчинг, оптимальный транспорт, ОДУ, U-Net, трансляция КТ-изображений.

Содержание

1	Введение	5
2	Обзор литературы	10
2.1	Синтез медицинских изображений	10
2.2	Трансляция КТ-контраста	12
2.3	Математические предпосылки: оптимальный транспорт и непре- рывные потоки	13
2.4	Флоу матчинг	13
2.5	Базовые архитектуры	14
3	Математические основы и постановка задачи	15
3.1	Обозначения	15
3.2	Постановка задачи	16
3.3	Теория вероятностных потоков	17
3.3.1	Уравнение непрерывности	17
3.3.2	Связь с оптимальным транспортом	18
3.4	Условный флоу матчинг	19
3.4.1	Маргинальное поле скоростей	19
3.4.2	Линейный интерполянт	20
3.5	Сравнение с диффузионными моделями	20
3.5.1	Прямой и обратный диффузионные процессы	20
3.5.2	Вероятностный ОДУ-поток диффузии	21
3.5.3	Структурные различия	22
3.6	Постановка задачи трансляции КТ	22
3.7	Численные методы интегрирования ОДУ	24
3.7.1	Локальная и глобальная погрешности	24
3.7.2	Метод Эйлера	25
3.7.3	Метод средней точки	25
3.7.4	Метод Рунге–Кутты 2-го порядка (RK2 / метод Хойна)	26

3.7.5	Метод Рунге–Кутты 4-го порядка (RK4)	26
3.7.6	Неявные и адаптивные методы (краткий обзор)	27
3.7.7	Точность при линейном поле скоростей	27
4	Описание предложенного метода	29
4.1	Общая схема метода MFM	29
4.2	Условный флоу матчинг	29
4.3	Архитектура TimeResNet	31
4.3.1	(а) Поблочное внедрение временного сигнала	31
4.3.2	(б) Свёрточный self-attention на буттлнеке	34
4.4	Базовые методы сравнения	37
5	Вычислительные эксперименты	39
5.1	Данные и предобработка	39
5.2	Детали обучения	39
5.3	Метрики качества	40
5.4	Результаты: контрастное $\rightarrow$ нативное	42
5.5	Результаты: нативное $\rightarrow$ контрастное	43
5.6	Клиническая значимость: MAE по анатомическим структурам .	44
5.7	Перцептивное качество: TotalSeg-LPIPS	44
5.8	Сравнение с ускоренным сэмплером DDIM	45
5.9	Одношаговый инференс: теория и эксперимент	46
5.10	Двунаправленность: теория vs. эксперимент	46
5.11	Анализ вклада компонент архитектуры TimeResNet	47
5.12	Межосевая согласованность	47
5.13	Качественный анализ	48
5.14	Применимость для задачи сегментации	50
6	Заключение	51

1 Введение

Машинное и глубокое обучение как инструмент порождающего моделирования

Машинное обучение — область прикладной математики, посвящённая восстановлению зависимостей по эмпирическим данным [2, 3]. Формально пусть $\mathcal{X} \subset \mathbb{R}^d$ — пространство объектов, $\mathcal{Y}$ — пространство ответов, π — неизвестное совместное распределение на $\mathcal{X} \times \mathcal{Y}$. Параметрическая модель $f_\theta : \mathcal{X} \rightarrow \mathcal{Y}$, $\theta \in \Theta$, обучается минимизацией эмпирического риска

$$\hat{\theta} = \arg \min_{\theta \in \Theta} \frac{1}{n} \sum_{i=1}^n \ell(f_\theta(\mathbf{x}_i), y_i), \quad (\mathbf{x}_i, y_i) \stackrel{\text{iid}}{\sim} \pi,$$

аппроксимирующего теоретический риск $R(\theta) = \mathbb{E}_{(\mathbf{x}, y) \sim \pi} \ell(f_\theta(\mathbf{x}), y)$. Глубокое обучение [4, 5] реализует f_θ как многослойную нейронную сеть — композицию параметризованных аффинных преобразований и нелинейностей; теоремы об универсальной аппроксимации [6, 7, 8] гарантируют, что класс таких функций плотен в $C(\mathcal{X})$ относительно равномерной нормы при минимальных условиях на нелинейность. Сочетание стохастического градиентного спуска [9, 10] с алгоритмом обратного распространения ошибки [11] и параллельных вычислений на графических ускорителях позволило применять модели с десятками миллионов параметров к задачам компьютерного зрения [12, 13], обработки естественного языка [14, 15] и порождающего моделирования.

В последнем направлении центральной задачей является аппроксимация распределения π_{data} либо его сэмплера. Классическая постановка состоит в построении параметрической плотности p_θ , минимизирующей расхождение Кульбака–Лейблера $\text{KL}(\pi_{\text{data}} \parallel p_\theta)$ [16, 17]. Альтернативный неявный подход — обучение порождающего отображения $G_\theta : \mathcal{Z} \rightarrow \mathcal{X}$, при котором $G_{\theta\#}\pi_{\text{prior}} \approx \pi_{\text{data}}$, как в генеративно-сопоставительных сетях [18, 19]. Современный сдвиг парадигмы связан с переходом от одношагового порождения к итеративному, основанному на стохастических дифференциальных уравнении-

ях — диффузионных моделях [20, 21, 22] и моделях согласования оценок (score matching [23, 24]). Их теоретическое обоснование лежит в области стохастического анализа, теории Фоккера–Планка и оптимального транспорта.

Качественный скачок 2022–2023 годов — появление флоу матчинга [25, 26, 27], который заменяет стохастический обратный процесс детерминированным потоком $\phi_t : \mathbb{R}^d \rightarrow \mathbb{R}^d$, заданным обыкновенным дифференциальным уравнением

$$\frac{d\phi_t(\mathbf{x})}{dt} = u_t(\phi_t(\mathbf{x})), \quad \phi_0 = \text{id},$$

с маргинальным полем скоростей u_t , согласованным с уравнением непрерывности $\partial_t \pi_t + \nabla \cdot (\pi_t u_t) = 0$ [28]. Поле u_t аппроксимируется нейронной сетью f_θ через симуляционно-свободный функционал, эквивалентный по градиентам ℓ_2 -регрессии на условную скорость [25]. Связь с минимизацией кинетической энергии Бенаму–Бренье [29] и теоремой Бренье [30] обеспечивает геометрическую интерпретацию: при линейном интерполянте траектории спрямляются, а сложность задачи аппроксимации падает. Практическое следствие — инференс за один шаг численного интегрирования вместо $T \sim 10^3$ шагов диффузии.

Прикладная задача: трансляция КТ-контраста

Изложенный математический аппарат естественно применяется к одной из наиболее остро стоящих задач медицинской визуализации — порождению парных контрастных и нативных компьютерных томограмм. Компьютерная томография занимает центральное место в современной клинической визуализации брюшной полости: ежегодно в США выполняется свыше 93 миллионов КТ-исследований [31], при этом стандартные диагностические протоколы нередко предусматривают сразу несколько серий — нативную (без контрастного усиления) и контрастную артериальную фазы, приобретаемые с интервалом 15–35 секунд после внутривенного введения йодсодержащего вещества [32]. Каждая из фаз несёт самостоятельную диагностическую ценность: нативная серия необходима для оценки плотности тканей в единицах Хаунсфилда, выявления кальцификатов и установления базового фона; контрастная — для чёткой

визуализации сосудистых структур и паренхиматозных органов.

Публично доступные наборы медицинских данных редко содержат обе фазы. Крупнейший на сегодняшний день датасет AbdomenAtlas [33] (8 448 томограмм) преимущественно ограничивается контрастной фазой. Отсутствие нативной серии делает невозможным ряд диагностических задач — от подсчёта кальций-скоринга до оценки плотностных характеристик тканей. Получение дополнительной КТ-серии влечёт лучевую нагрузку, ограничивает пропускную способность оборудования и сопряжено с риском нефропатии, индуцированной контрастным веществом [34].

Совокупность этих обстоятельств формирует практический запрос: построить алгоритм трансляции между нативными и контрастными КТ. Решение задачи позволит расширять обучающие наборы данных без проведения дополнительных исследований. Особенностью задачи, отличающей её от большинства приложений синтеза медицинских изображений, является требование точного воспроизведения абсолютных значений плотности в HU — стандартизированной радиологической шкалы, где диагностические пороги (например, 70 HU для кальцификации) требуют численного, а не лишь визуального, соответствия.

Применение методов глубокого обучения к данной задаче исследовалось в нескольких направлениях: регрессионные сети [35], генеративно-состязательные сети [36, 37], диффузионные модели [37, 38] и специализированный метод SMILE [1]. Диффузионные подходы демонстрируют высокое качество, однако страдают от вычислительно затратного многошагового вывода. Применение флоу матчинга [25, 26] к медицинской визуализации остаётся малоизученным [39, 40]; ни одна из известных работ не рассматривала его для задачи парной трансляции КТ-контраста, при которой пары $(\mathbf{x}_N, \mathbf{x}_C)$ от одного пациента дают эмпирическое приближение оптимального транспортного сочленения.

Постановка задачи и вклад работы. В данной работе исследуется математическая задача построения непрерывного потока, согласующего распре-

деления нативных π_N и контрастных π_C КТ-срезов, в рамках теории условного флоу матчинга. Предлагается метод **Medical Flow Matching (MFM)** и сопутствующая нейросетевая параметризация **TimeResNet**, служащая инструментом экспериментальной проверки теоретических утверждений о (а) симуляционно-свободном обучении, (б) оптимальности одношагового интегрирования при линейном интерполянте и (в) двунаправленности трансляции, вытекающей из симметрии интерполянта.

Основные результаты работы:

1. Разработан конвейер условного флоу матчинга для двунаправленной трансляции КТ-контраста, требующий лишь однократного вычисления сети при инференсе и обеспечивающий ускорение в **354 раза** относительно DDPM (1000 шагов).
2. Предложена архитектура TimeResNet с (а) пошаговым синусоидальным внедрением временного сигнала через аффинную модуляцию в каждый блок и (б) свёрточным модулем self-attention на буттлнеке; анализ вклада компонент подтверждает значимость каждого из них (+1.71 и +1.77 NU MAE при удалении).
3. Экспериментально подтверждено, что единственная сеть f_θ работает в обоих направлениях трансляции, что вдвое сокращает затраты на обучение. Сгенерированные изображения пригодны для обучения последующих сегментационных моделей: Dice = 0.926 против 0.966 на реальных данных.

Структура работы. В разделе 2 приводится обзор релевантных публикаций, охватывающий методы машинного обучения для синтеза медицинских изображений, задачу трансляции КТ-контраста и методологию флоу матчинга. Раздел 3 фиксирует обозначения, формулирует математическую постановку задачи и излагает теоретические основы: уравнение непрерывности, связь с оптимальным транспортом, теорему симуляционно-свободного обучения,

сравнение с диффузионными моделями и численные методы интегрирования ОДУ. Раздел 4 содержит описание метода MFM и архитектуры TimeResNet. В разделе 5 представлены данные, детали обучения, метрики качества, количественные и качественные результаты, анализ вклада компонент и анализ применимости для задачи сегментации. Раздел 6 подводит итог проделанной работы и намечает направления дальнейших исследований.

2 Обзор литературы

2.1 Синтез медицинских изображений

Эпоха классических методов. До широкого распространения глубоких порождающих моделей задача синтеза медицинских изображений решалась преимущественно средствами вычислительной геометрии, статистики формы и физики формирования изображения. Первая большая ветвь — цифровые анатомические фантомы. Обер-Броше и соавт. [41] построили библиотеку из двадцати высокоразрешающих цифровых фантомов мозга на основе МРТ нормальных добровольцев из проекта BrainWeb. Каждый фантом представлял собой объёмную карту вероятностей принадлежности вокселя к одному из тканевых классов и использовался для генерации синтетических МРТ-данных с известным эталоном при разработке и валидации алгоритмов сегментации. Сегарс и соавт. [42] разработали четырёхмерный фантом XCAT (eXtended CArdiac-Torso), описывающий анатомию торса с помощью NURBS-поверхностей и моделирующий дыхательное и сердечное движения; XCAT поныне остаётся стандартом в задачах симуляции КТ- и ПЭТ-измерений и в задачах оптимизации протоколов лучевой дозы.

Вторая ветвь классики — статистические модели формы и текстуры. Активные модели внешнего вида (Active Appearance Models, AAM), предложенные Кутсом, Эдвардсом и Тэйлором [43], описывают объект совместным распределением координат опорных точек и интенсивностей в области, ограниченной этими точками, после устранения ковариации между формой и яркостью. ААМ позволяли как параметрический синтез вариаций анатомии (путём сэмплирования из обученной модели в собственном базисе), так и анализ — регистрацию модели на новом изображении градиентным методом. Применения охватывали кардиальную МРТ, церебральную МРТ, дентальную рентгенографию и офтальмологию.

Все классические методы объединяет одно фундаментальное ограничение: распределение, из которого они порождают, лежит на низкоразмерном

линейном многообразии в пространстве изображений (РСА-базис для ААМ, заданное семейство фантомов для ХСАТ/BrainWeb). Это исключает воспроизведение тонкой патологической текстуры, межпациентной вариативности на уровне отдельных вокселей и нелинейных эффектов формирования изображения (артефакты, шум сканера, частичные объёмы). Кроме того, расширение модели на новую анатомическую область требует ручной разметки сотен исследований.

Глубокие порождающие модели. Качественный сдвиг произошёл с распространением глубоких порождающих моделей. Первое поколение опиралось на генеративно-состязательные сети (GAN) [18]: два состязющихся параметризованных распределения — порождающее и распознающее — сходятся к равновесию, при котором сгенерированные образцы статистически неотличимы от реальных. В задаче трансляции МРТ в КТ Ху и соавт. [36] предложили двунаправленную GAN-архитектуру, обеспечивающую взаимно согласованные преобразования. Для синтеза ПЭТ из МРТ разработаны специализированные фреймворки на основе условных GAN [44, 45, 46], нередко с трёхмерными сверточными кодировщиками [46] и механизмами self-attention [47]. Для задачи суперразрешения предложены многомасштабные сети [48] и GAN-CIRCLE [49]. Отдельного упоминания заслуживают работы по синтезу данных для реконструкции [50, 51], где диффузионные модели позволяют решать проблему неполных измерений. Несмотря на впечатляющие результаты, GAN-подход имеет хорошо известные недостатки: коллапс мод, нестабильность обучения и отсутствие согласованной меры правдоподобия, что затрудняет их использование в задачах с требованием точной воспроизводимости числовых значений — таких как КТ в НУ.

Диффузионные вероятностные модели [20, 21] принесли очередной качественный скачок. Их теоретическое преимущество над GAN — стабильное обучение с явным правдоподобием, а недостаток — медленный многошаговый инференс. Ромбах и соавт. [52] показали, что латентные диффузионные модели способны синтезировать изображения высокого разрешения при уме-

ренных вычислительных затратах. В медицинской визуализации они нашли применение для гармонизации МРТ [53], перевода МРТ в КТ [54], трёхмерного синтеза [55, 56] и цикловых MRI-КТ задач [57]. Тем не менее ключевым ограничением диффузионных методов остаётся их медлительность: получение одного образца требует нескольких сотен шагов денойзинга, что неприемлемо для клинических приложений реального времени и для обучения downstream-моделей на синтетических данных.

2.2 Трансляция КТ-контраста

Задача синтеза виртуальных нативных (или контрастных) КТ-изображений рассматривалась ещё в контексте двухэнергетической КТ (ДЭКТ). Вирар и соавт. [58] дают обширный клинический обзор приложений ДЭКТ для виртуального нативного изображения в брюшной полости и малом тазу. Кин и соавт. [35] предложили генерацию глубокого виртуального нативного КТ с применением двухслойной ДЭКТ для радиотерапевтического планирования. Пан и соавт. [59] и Каплантар и соавт. [37] использовали CycleGAN для синтеза нативной серии из контрастных МРТ и КТ соответственно, обходясь без парных обучающих данных. Ким и соавт. [38] разработали адаптивную латентную диффузионную модель для трёхмерного межмодального МРТ-синтеза.

Наиболее близкой к предлагаемому методу является работа Лю и соавт. [1] — метод SMILE, применяющий анатомически-управляемый диффузионный подход к задаче контрастного усиления. Авторы вводят анатомическое предобуславливание и специальные потери, однако базовая архитектура DDPM сохраняет многошаговый инференс. На наших данных SMILE показал значительно более высокую ошибку MAE (30.22 HU против 4.25 HU у MFM), что, по всей видимости, связано со сдвигом распределений между данными, использованными для создания предобученной модели, и нашим датасетом.

2.3 Математические предпосылки: оптимальный транспорт и непрерывные потоки

Флоу матчинг опирается на классическую теорию переноса меры. Монж в 1781 году поставил задачу о минимизации суммарной стоимости перевозки массы; Канторович [60] обобщил её до релаксации, допускающей расщепление массы. Бренье [30] доказал существование и единственность оптимального транспортного отображения при квадратичной стоимости и абсолютно непрерывной начальной мере; в дальнейшем теория получила систематическое изложение в работах Виллани [28] и Сантамбрджо. Геометрическая динамическая переформулировка — задача Бенаму–Бренье [29] — сводит расстояние Вассерштейна $W_2^2(\pi_0, \pi_1)$ к минимизации кинетической энергии непрерывного потока, удовлетворяющего уравнению непрерывности. Именно эта переформулировка лежит в основе современного флоу матчинга.

Параллельная линия исследований развивает порождающие модели на основе непрерывных нормализующих потоков — Neural ODE [61] и FFJORD [62]: распределение задаётся как образ простой меры через решение ОДУ с обучаемой правой частью. Главное препятствие исторически — необходимость симулировать траекторию и считать определитель якобиана при обучении максимума правдоподобия.

2.4 Флоу матчинг

Симуляционно-свободная парадигма обучения непрерывных потоков предложена практически одновременно Липманом и соавт. [25], Алберго и Ванден-Ейнденом [26] (формализм стохастических интерполянтов) и Лю и соавт. [27] (Rectified Flow). Идея состоит в том, чтобы соединить шумовое распределение с распределением данных посредством явного интерполянта $\mathbf{x}_t = \alpha_t \mathbf{x}_0 + \sigma_t \mathbf{x}_1$ и обучить нейронную сеть предсказывать условную производную $\partial_t \mathbf{x}_t$; теорема о градиентной эквивалентности гарантирует, что такая регрессия минимизирует расхождение между сетью и истинным маргинальным полем скоростей. Тонг

и соавт. [63] обобщили подход с использованием минибатчного оптимального транспорта, получив более прямые пути и тем самым улучшив качество одношагового инференса. Сонг и соавт. [22] ранее показали, что само диффузионное обучение можно интерпретировать как обучение поля скоростей вероятностного потока ОДУ.

В медицинской визуализации флоу матчинг только начинает завоёвывать позиции. Яздани и соавт. [39] рассмотрели его для синтеза медицинских изображений в целом, продемонстрировав баланс между скоростью и качеством. Рейно и соавт. [40] разработали EchoFlow — фундаментальную модель для генерации ультразвуковых изображений сердца. При этом ни одна из известных работ не применяла флоу матчинг к задаче парной трансляции КТ-контраста и не предлагала специализированную архитектуру для этого класса задач.

2.5 Базовые архитектуры

Значительная часть предлагаемых экспериментальных сравнений опирается на архитектуры, хорошо зарекомендовавшие себя в медицинской сегментации. U-Net [64] — классическая архитектура с энкодером-декодером и пропускными связями — остаётся стандартом де-факто для задач с попиксельным предсказанием. SegResNet [65] расширяет эту схему с помощью остаточных блоков и вариационного автокодировщика для регуляризации. SwinUNETR [66] заменяет сверточный энкодер иерархическим трансформером на основе sliding window Swin, что позволяет захватывать долгодистанционные зависимости при умеренной вычислительной стоимости. UMambaBot [67] включает модели пространства состояний (Mamba) в U-Net фреймворк для эффективного моделирования длинных зависимостей в биомедицинских изображениях.

Для сравнения с диффузионными моделями используются DDPM [21] с условной подачей исходного изображения и ускоренным семплированием DDIM [68]. Downstream-сегментация оценивается nnUNet v2 [69] — самоконфигурирующимся фреймворком, задающим стандарт в данной области.

3 Математические основы и постановка задачи

Настоящий раздел — центральная теоретическая часть работы. Здесь фиксируются обозначения, формулируется математическая постановка задачи в терминах переноса меры, излагается аппарат вероятностных потоков и условного флюидного матчинга, обсуждается связь с теорией оптимального транспорта и приводится подробное сравнение с диффузионными моделями. В завершение раздела изучаются численные методы интегрирования получающегося ОДУ и обосновывается, почему при линейном интерполянте достаточно одношагового метода Эйлера. Нейронная сеть f_θ , появляющаяся в формулировках, — не более чем инструмент аппроксимации искомого поля скоростей; её конкретная архитектура отложена до раздела 4.

3.1 Обозначения

Строчные полужирные буквы обозначают векторы: $\mathbf{x}, \mathbf{v} \in \mathbb{R}^d$, заглавные полужирные — матрицы. Через π (с нижним индексом) обозначается вероятностная мера на $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$; в частности, π_0 и π_1 — начальная и целевая меры. Их плотности (по мере Лебега) обозначаются p_0, p_1 соответственно; для общей меры π пишется p или $d\pi/d\lambda$. Для измеримого отображения $T : \mathbb{R}^d \rightarrow \mathbb{R}^d$ через $T_\# \pi$ обозначается *образ* меры π : $(T_\# \pi)(A) := \pi(T^{-1}(A))$ для $A \in \mathcal{B}(\mathbb{R}^d)$. Символ $\mathcal{U}[0,1]$ — равномерное распределение на $[0,1]$, $\mathcal{N}(\mu, \sigma^2)$ — нормальное; $\Pi(\pi_0, \pi_1)$ — множество совместных мер с маргиналями π_0, π_1 . Параметры нейронной сети обозначаются через θ , $\odot$ — поэлементное умножение. Норма $\|\cdot\|_2$ — евклидова на $\mathbb{R}^d$, $W_2(\pi_0, \pi_1)$ — 2-расстояние Вассерштейна.

Термин *нативный* обозначает КТ без контраста; *контрастный* — артериальную фазу. Все срезы имеют размер 512×512 пикселей, интенсивности задаются в единицах Хаунсфилда (HU).

3.2 Постановка задачи

Пусть π_N и π_C — вероятностные меры на $\mathbb{R}^d$ ($d = 512^2$), описывающие распределения нативных и контрастных КТ-срезов брюшной полости соответственно. Предполагается наличие парных наблюдений $(\mathbf{x}_N, \mathbf{x}_C) \sim \gamma$, где $\gamma \in \Pi(\pi_N, \pi_C)$ — совместная мера с заданными маргиналями (на практике — эмпирическая мера, образованная парами серий одного пациента после регистрации).

Задача 1 (Транспортная задача в строгой форме). *Найти измеримое отображение $T : \mathbb{R}^d \rightarrow \mathbb{R}^d$, такое что $T_{\#}\pi_0 = \pi_1$, то есть для каждого $\mathbf{x}_0 \sim \pi_0$ образ $T(\mathbf{x}_0)$ распределён согласно π_1 .*

Уже здесь видны фундаментальные сложности, отделяющие математическую формулировку от прикладной:

1. *Существование.* При $d \gg 1$ и многомодальных π_0, π_1 существование единственного измеримого T не гарантировано без дополнительных предположений (например, абсолютной непрерывности π_0 относительно меры Лебега [30]).
2. *Однозначность.* Любая композиция $T \circ S$, где S сохраняет π_0 , также решает задачу 1 — транспортных отображений бесконечно много, и без дополнительного критерия (например, минимизации кинетической энергии) задача недоопределена.
3. *Нелинейность.* Подмножество $\{T : T_{\#}\pi_0 = \pi_1\}$ не образует линейного пространства, что исключает напрямую градиентные методы оптимизации.

Флоу матчинг обходит эти трудности через релаксацию: вместо одного отображения ищется однопараметрическое семейство $\{\phi_t\}_{t \in [0,1]}$, плавно соединяющее тождественное отображение с искомым переносом. Формально:

Задача 2 (Динамическая релаксация). *Найти семейство диффеоморфизмов $\phi_t : \mathbb{R}^d \rightarrow \mathbb{R}^d$, $t \in [0,1]$, такое что $\phi_0 = \text{id}$, $(\phi_1)_{\#}\pi_0 = \pi_1$, и порождающее его*

поле скоростей $u_t : \mathbb{R}^d \rightarrow \mathbb{R}^d$ удовлетворяет некоторому критерию регулярности (например, минимизирует кинетическую энергию — см. §3.3.2).

Данная работа сосредотачивается на математической природе задачи 2, а нейронная сеть f_θ выступает лишь как универсальный аппроксиматор поля u_t , выбранный по соображениям выразительности и удобства оптимизации.

3.3 Теория вероятностных потоков

3.3.1 Уравнение непрерывности

Определение 1 (Вероятностный поток). Пусть $u : [0,1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ — измеримое поле скоростей, удовлетворяющее локально условию Липшица по пространственной переменной. Поток, порождаемый u , есть решение задачи Коши:

$$\frac{d}{dt}\phi_t(\mathbf{x}) = u_t(\phi_t(\mathbf{x})), \quad \phi_0(\mathbf{x}) = \mathbf{x}. \quad (1)$$

Тогда $\phi_t : \mathbb{R}^d \rightarrow \mathbb{R}^d$ — диффеоморфизм для каждого $t \in [0,1]$.

Эволюция начального распределения π_0 под действием потока описывается семейством мер $\pi_t := (\phi_t)_\# \pi_0$. Согласно классическому результату из теории переноса (см. [28, гл. 5]), плотность p_t меры π_t удовлетворяет уравнению непрерывности:

$$\frac{\partial p_t}{\partial t} + \nabla \cdot (p_t u_t) = 0. \quad (2)$$

Уравнение (2) является ключевым: оно связывает поле скоростей u_t с эволюцией вероятностной меры. Если u_t задано — π_t однозначно определена начальной мерой. Обратно: задав граничные условия π_0 и π_1 , можно искать поле u_t , обеспечивающее нужный перенос. Уравнение (2) имеет бесконечное число решений (любое поле, совпадающее с u_t “по существу” на носителе p_t , эквивалентно); среди них естественно выбирать “простейшее” в некоторой норме.

3.3.2 Связь с оптимальным транспортом

Идея этого раздела простая: среди всех способов перевезти распределение π_0 в π_1 существует один особенный — “прямой”. Чтобы формализовать, какой именно, нужно решить, что значит “прямой”.

Представим, что массу одной плотности нужно физически перевезти в другую за единицу времени. Если каждая частица движется со скоростью $\mathbf{v}$, то затрачиваемая ею кинетическая энергия пропорциональна $\|\mathbf{v}\|_2^2$. Суммарная энергия по всем частицам и за всё время:

$$\mathcal{E}(u) = \int_0^1 \int_{\mathbb{R}^d} \|u_t(\mathbf{x})\|_2^2 p_t(\mathbf{x}) d\mathbf{x} dt = \int_0^1 \mathbb{E}_{\mathbf{x} \sim \pi_t} [\|u_t(\mathbf{x})\|_2^2] dt. \quad (3)$$

Здравый смысл подсказывает: чтобы не тратить лишнюю энергию, частицы должны двигаться по прямым с постоянной скоростью. Это и есть содержание классической теоремы Бенаму–Бренье [29]: минимум $\mathcal{E}(u)$ среди всех допустимых потоков равен квадрату расстояния Вассерштейна, $W_2^2(\pi_0, \pi_1)$, а минимизирующий поток — прямолинейная интерполяция между парами точек $(\mathbf{x}_0, \mathbf{x}_1)$.

Чтобы понять, какие именно пары соединять прямыми, нужно зафиксировать совместное распределение $\gamma \in \Pi(\pi_0, \pi_1)$ — то есть указать, “куда какая частица едет”. Оптимальный выбор γ^* есть решение задачи Канторовича [60]:

$$\gamma^* = \arg \min_{\gamma \in \Pi(\pi_0, \pi_1)} \int \|\mathbf{x}_1 - \mathbf{x}_0\|_2^2 d\gamma(\mathbf{x}_0, \mathbf{x}_1).$$

По теореме Бренье [30], при абсолютной непрерывности π_0 это γ^* сосредоточено на графике градиента выпуклой функции — то есть оптимальные пары соединены однозначным детерминированным отображением.

Утверждение 1 (Оптимальность прямолинейных траекторий). *При фиксированном совместном распределении $\gamma \in \Pi(\pi_0, \pi_1)$ поток*

$$\phi_t(\mathbf{x}_0) = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1, \quad (\mathbf{x}_0, \mathbf{x}_1) \sim \gamma,$$

минимизирует кинетическую энергию (3) среди всех потоков с теми же концевыми точками. Соответствующее условное поле скоростей $u_t(\cdot \mid \mathbf{x}_1) = \mathbf{x}_1 - \mathbf{x}_0$ постоянно по t .

В прикладной части работы используется не оптимальный по Канторовичу γ^* , а эмпирическое совместное распределение — пары $(\mathbf{x}_N, \mathbf{x}_C)$ срезов одного пациента после регистрации. Такие пары уже образуют разумное приближение к оптимальному сочленению, так как соответствуют одной и той же анатомии. Поэтому полученные траектории — “почти прямые”, а кривизна выученного поля u_t — мала. Это техническое наблюдение в дальнейшем (§3.7) превращается в утверждение об одношаговости численного интегрирования.

3.4 Условный флоу матчинг

3.4.1 Маргинальное поле скоростей

Пусть $p_t(\mathbf{x})$ — плотность π_t . Истинное (маргинальное) поле скоростей, порождающее путь $\{\pi_t\}$, по построению Липмана и соавт. [25] имеет вид:

$$u_t(\mathbf{x}) = \frac{\int u_t(\mathbf{x} \mid \mathbf{x}_1) p_t(\mathbf{x} \mid \mathbf{x}_1) p_1(\mathbf{x}_1) d\mathbf{x}_1}{p_t(\mathbf{x})}, \quad (4)$$

где $u_t(\mathbf{x} \mid \mathbf{x}_1)$ — условное поле скоростей при фиксированной точке назначения $\mathbf{x}_1$. Непосредственное вычисление (4) невозможно: интеграл в числителе и плотность p_t в знаменателе аналитически неизвестны. Однако обучение можно вести *симуляционно-свободно*, используя условные величины:

Теорема 1 (Симуляционно-свободное обучение [25, Theorem 2]). Пусть $f_\theta : \mathbb{R}^d \times [0, 1] \rightarrow \mathbb{R}^d$ — произвольная параметрическая функция. Маргинальная потеря флоу матчинга

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0, 1], \mathbf{x} \sim \pi_t} [\|f_\theta(\mathbf{x}, t) - u_t(\mathbf{x})\|_2^2] \quad (5)$$

и её условный аналог

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0, 1], (\mathbf{x}_0, \mathbf{x}_1) \sim \gamma} [\|f_\theta(\mathbf{x}_t, t) - u_t(\mathbf{x}_t \mid \mathbf{x}_1)\|_2^2] \quad (6)$$

имеют одинаковые градиенты по θ : $\nabla_{\theta} \mathcal{L}_{\text{FM}} = \nabla_{\theta} \mathcal{L}_{\text{CFM}}$.

Набросок. Раскроем квадрат в (5):

$$\mathbb{E}[\|f_{\theta} - u_t\|^2] = \mathbb{E}\|f_{\theta}\|^2 - 2\mathbb{E}\langle f_{\theta}, u_t \rangle + \mathbb{E}\|u_t\|^2.$$

Третий член не зависит от θ и обнуляется при дифференцировании. Используя (4), получим:

$$\begin{aligned} \mathbb{E}_{\mathbf{x} \sim \pi_t} \langle f_{\theta}(\mathbf{x}, t), u_t(\mathbf{x}) \rangle &= \int f_{\theta}(\mathbf{x}, t)^{\top} \left[\int u_t(\mathbf{x} \mid \mathbf{x}_1) p_t(\mathbf{x} \mid \mathbf{x}_1) p_1(\mathbf{x}_1) d\mathbf{x}_1 \right] d\mathbf{x} \\ &= \mathbb{E}_{(\mathbf{x}, \mathbf{x}_1) \sim p_t(\cdot \mid \mathbf{x}_1) p_1} \langle f_{\theta}(\mathbf{x}, t), u_t(\mathbf{x} \mid \mathbf{x}_1) \rangle. \end{aligned}$$

Аналогично преобразуется первый член. Разница между (5) и (6) оказывается константой по θ , что и доказывает совпадение градиентов. $\square$

Теорема 1 обеспечивает обучаемость: для оценки градиента достаточно сэмплировать пары $(\mathbf{x}_0, \mathbf{x}_1) \sim \gamma$ и точки $\mathbf{x}_t$ из явного условного интерполянта, не симулируя траектории.

3.4.2 Линейный интерполянт

При выборе линейного пути $(1-t)\mathbf{x}_0 + t\mathbf{x}_1$ условное поле скоростей принимает форму:

$$\mathbf{x}_t = (1-t)\mathbf{x}_0 + t\mathbf{x}_1, \quad u_t(\mathbf{x}_t \mid \mathbf{x}_1) = \mathbf{x}_1 - \mathbf{x}_0. \quad (7)$$

Заметим, что целевая скорость $\mathbf{x}_1 - \mathbf{x}_0$ не зависит от t . Это означает, что нейронная сеть обучается предсказывать стационарное относительно времени поле, тогда как диффузионные модели вынуждены моделировать существенно зависящий от t шумовой предиктор $\epsilon_{\theta}(\mathbf{x}_t, t)$ при $t \in \{0, 1, \dots, T\}$. Численные следствия этого факта обсуждаются в §3.7.

3.5 Сравнение с диффузионными моделями

3.5.1 Прямой и обратный диффузионные процессы

В диффузионных вероятностных моделях (DDPM) [20, 21] *прямой процесс* постепенно зашумляет данные, переводя их в стандартную гауссиану. В дис-

кретной форме задаётся марковской цепью

$$q(\mathbf{x}_t \mid \mathbf{x}_{t-1}) = \mathcal{N}(\sqrt{1 - \beta_t} \mathbf{x}_{t-1}, \beta_t \mathbf{I}), \quad t = 1, \dots, T, \quad (8)$$

с расписанием $\{\beta_t\}_{t=1}^T \subset (0,1)$. Композиция шагов даёт замкнутую формулу:

$$q(\mathbf{x}_t \mid \mathbf{x}_0) = \mathcal{N}(\sqrt{\bar{\alpha}_t} \mathbf{x}_0, (1 - \bar{\alpha}_t) \mathbf{I}), \quad \bar{\alpha}_t = \prod_{s=1}^t (1 - \beta_s). \quad (9)$$

При $T \rightarrow \infty$ и подходящем выборе β_t марковская цепь (8) сходится к стохастическому дифференциальному уравнению [22]:

$$d\mathbf{x} = -\frac{1}{2}\beta(t)\mathbf{x} dt + \sqrt{\beta(t)} d\mathbf{W}_t,$$

где $\mathbf{W}_t$ — стандартное винеровское движение. Соответствующее уравнение Фоккера–Планка для плотности q_t :

$$\partial_t q_t = \nabla \cdot \left(\frac{1}{2} \beta(t) \mathbf{x} q_t \right) + \frac{1}{2} \beta(t) \Delta q_t.$$

Обратный процесс в форме SDE имеет вид (Андерсон, 1982; см. [22]):

$$d\mathbf{x} = \left[-\frac{1}{2}\beta(t)\mathbf{x} - \beta(t)\nabla_{\mathbf{x}} \log q_t(\mathbf{x}) \right] dt + \sqrt{\beta(t)} d\bar{\mathbf{W}}_t, \quad (10)$$

где $\bar{\mathbf{W}}_t$ — обратное винеровское движение. Ключевой ингредиент — *скоринг-функция* $s(\mathbf{x}, t) := \nabla_{\mathbf{x}} \log q_t(\mathbf{x})$, которую и обучают предсказывать нейронной сетью через денойзинг-скоринг-матчинг [23, 24]:

$$\mathcal{L}_{\text{DSM}}(\theta) = \mathbb{E}_{t, \mathbf{x}_0, \epsilon} [\|s_\theta(\mathbf{x}_t, t) + \epsilon / \sqrt{1 - \bar{\alpha}_t}\|_2^2], \quad \mathbf{x}_t = \sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon. \quad (11)$$

На практике вместо s_θ обычно обучают эквивалентный шумовой предиктор $\epsilon_\theta(\mathbf{x}_t, t) \approx -\sqrt{1 - \bar{\alpha}_t} s(\mathbf{x}_t, t)$.

3.5.2 Вероятностный ОДУ-поток диффузии

Сонг и соавт. [22] показали, что у обратного SDE (10) имеется эквивалентный по маргиналям детерминированный спутник:

$$\frac{d\mathbf{x}}{dt} = -\frac{1}{2}\beta(t) [\mathbf{x} + \nabla_{\mathbf{x}} \log q_t(\mathbf{x})], \quad (12)$$

называемый *вероятностным потоковым ОДУ*. Эта формула проясняет глубокую связь диффузии и флоу матчинга: оба метода обучают поле, порождающее перенос меры, но конкретный вид поля и интерполянта различен.

3.5.3 Структурные различия

Замечание (Структурное различие). *(i) ОДУ (1) флоу матчинга детерминировано, тогда как обратный диффузионный SDE (10) стохастичен; (ii) целевое поле (7) не зависит от t , что существенно снижает сложность задачи аппроксимации; (iii) прямые траектории при линейном интерполянте обладают нулевой кривизной, что позволяет численно интегрировать ОДУ за один шаг (Эйлер); диффузионные ОДУ (12) имеют существенно нелинейные траектории, что требует многих шагов.*

Ускоренные сэмплеры DDIM [68] сокращают число шагов до 50–100 ценой ухудшения качества. В разделе 5.8 приводится прямое сравнение: даже DDIM-50 остаётся в 40 раз медленнее и в 5 раз хуже MFM по MAE.

3.6 Постановка задачи трансляции КТ

Применим общую теорию из §§3.4–3.5 к конкретной задаче трансляции КТ. Положим $\pi_0 = \pi_N$, $\pi_1 = \pi_C$ (для прямого направления; обратное получается заменой пределов интегрирования). При линейном интерполянте (7) условная потеря (6) принимает вид

$$\mathcal{L}_{\text{MFM}}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0,1]} \mathbb{E}_{(\mathbf{x}_N, \mathbf{x}_C) \sim \gamma} [\|f_\theta((1-t)\mathbf{x}_N + t\mathbf{x}_C, t) - (\mathbf{x}_C - \mathbf{x}_N)\|_2^2]. \quad (13)$$

Двунаправленная трансляция. Из симметрии линейного интерполянта (7) следует, что единственная обученная сеть f_θ реализует трансляцию в обоих направлениях. Сформулируем это утверждение формально.

Утверждение 2 (Двунаправленность MFM). *Пусть f_{θ^*} — минимизатор условной потери (13), в которой выборка пар $(\mathbf{x}_N, \mathbf{x}_C) \sim \gamma$ симметрична*

относительно перестановки концевых точек: на каждой итерации с равной вероятностью предъявляется как пара $(\mathbf{x}_0, \mathbf{x}_1) = (\mathbf{x}_N, \mathbf{x}_C)$, так и $(\mathbf{x}_C, \mathbf{x}_N)$. Тогда для любого $\mathbf{x} \in \text{supp}(\pi_N \cup \pi_C)$ выполнено:

$$\hat{\mathbf{x}}_C = \mathbf{x} + \int_0^1 f_{\theta^*}(\mathbf{x}_t, t) dt, \quad \hat{\mathbf{x}}_N = \mathbf{x} + \int_1^0 f_{\theta^*}(\mathbf{x}_t, t) dt, \quad (14)$$

где $\mathbf{x}_t$ — решение ОДУ (1) с соответствующим начальным условием. Иными словами, единственное поле f_{θ^*} реализует оба отображения $\pi_N \rightarrow \pi_C$ и $\pi_C \rightarrow \pi_N$, и

$$f_{\theta^*} = \arg \min_f [\mathcal{L}_{\text{MFM}}^{N \rightarrow C}(f) + \mathcal{L}_{\text{MFM}}^{C \rightarrow N}(f)]. \quad (15)$$

Доказательство. Запишем потерю (13) в обобщённой форме для пары $(\mathbf{x}_0, \mathbf{x}_1)$:

$$\mathcal{L}(\theta; \mathbf{x}_0, \mathbf{x}_1) = \mathbb{E}_{t \sim \mathcal{U}[0,1]} [\|f_{\theta}((1-t)\mathbf{x}_0 + t\mathbf{x}_1, t) - (\mathbf{x}_1 - \mathbf{x}_0)\|_2^2].$$

Сделаем замену переменной $s = 1 - t$. Поскольку $ds = -dt$ и $s \sim \mathcal{U}[0,1]$ вместе с t , получаем

$$\begin{aligned} \mathcal{L}(\theta; \mathbf{x}_0, \mathbf{x}_1) &= \mathbb{E}_{s \sim \mathcal{U}[0,1]} [\|f_{\theta}(s\mathbf{x}_0 + (1-s)\mathbf{x}_1, 1-s) - (\mathbf{x}_1 - \mathbf{x}_0)\|_2^2] \\ &= \mathbb{E}_{s \sim \mathcal{U}[0,1]} [\| -(-f_{\theta}(s\mathbf{x}_0 + (1-s)\mathbf{x}_1, 1-s)) - (\mathbf{x}_1 - \mathbf{x}_0) \|_2^2]. \end{aligned}$$

Введём симметризованную сеть $\tilde{f}_{\theta}(\mathbf{x}, t) := -f_{\theta}(\mathbf{x}, 1-t)$ и пару с переставленными концами $(\mathbf{x}'_0, \mathbf{x}'_1) := (\mathbf{x}_1, \mathbf{x}_0)$. Тогда последнее выражение равно $\mathcal{L}(\tilde{\theta}; \mathbf{x}'_0, \mathbf{x}'_1)$ — потере с обращённым направлением.

По условию симметрии выборки γ относительно перестановки концов,

$$\mathbb{E}_{(\mathbf{x}_0, \mathbf{x}_1) \sim \gamma} \mathcal{L}(\theta; \mathbf{x}_0, \mathbf{x}_1) = \mathbb{E}_{(\mathbf{x}'_0, \mathbf{x}'_1) \sim \gamma} \mathcal{L}(\theta; \mathbf{x}'_1, \mathbf{x}'_0) = \mathbb{E}_{(\mathbf{x}'_0, \mathbf{x}'_1) \sim \gamma} \mathcal{L}(\tilde{\theta}; \mathbf{x}'_0, \mathbf{x}'_1).$$

Следовательно, минимизатор θ^* обоюдно оптимизирует и прямое, и обратное направления, что доказывает (15).

Для проверки (14) заметим: подставив начальное условие $\mathbf{x}(0) = \mathbf{x}_N$ и интегрируя (1) от 0 к 1, получаем $\hat{\mathbf{x}}_C$. Заменой $s = 1 - t$ и в силу установленной симметрии $f_{\theta^*}(\mathbf{x}, t) = -f_{\theta^*}(\mathbf{x}, 1-t) \circ (\text{перестановка концов})$, интегрирование от 1 к 0 при начальном условии $\mathbf{x}(1) = \mathbf{x}_C$ даёт $\hat{\mathbf{x}}_N$, что и требовалось. $\square$

Конкретно для задачи трансляции КТ это означает:

- нативное $\rightarrow$ контрастное: интегрирование (1) от $t = 0$ к $t = 1$;
- контрастное $\rightarrow$ нативное: интегрирование от $t = 1$ к $t = 0$.

Вместо двух специализированных моделей ($f_\theta^{N \rightarrow C}$ и $f_\theta^{C \rightarrow N}$) требуется одна, что вдвое снижает затраты на обучение и хранение весов. Этот теоретический вывод подтверждается экспериментально: однонаправленный вариант TimeResNet даёт $\text{MAE} = 4.22 \text{ HU}$, что не отличается статистически значимо от 4.25 HU у двунаправленного MFM (таблица 8).

3.7 Численные методы интегрирования ОДУ

При инференсе уравнение (1) решается численно на отрезке $t \in [0, 1]$. Зафиксируем равномерную сетку $\{t_k = kh\}_{k=0}^N$, $h = 1/N$, и обозначим $\hat{\mathbf{x}}_k \approx \phi_{t_k}(\mathbf{x}_0)$. Задача Коши:

$$\frac{d\mathbf{x}}{dt} = f_\theta(\mathbf{x}, t), \quad \mathbf{x}(0) = \mathbf{x}_0. \quad (16)$$

Изложение в этом разделе самодостаточно: вводятся понятия локальной и глобальной погрешности, теоремы устойчивости, разбираются методы Эйлера, средней точки, Рунге–Кутты 2-го и 4-го порядков, обсуждаются неявные и адаптивные схемы, а в конце доказывается, что при линейном интерполанте простейший метод Эйлера — оптимальный выбор.

3.7.1 Локальная и глобальная погрешности

Определение 2 (Локальная погрешность усечения). Для одношаговой схемы $\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + h \Phi(\hat{\mathbf{x}}_k, t_k, h)$ локальная погрешность определяется как

$$\tau_k = \mathbf{x}(t_{k+1}) - \mathbf{x}(t_k) - h \Phi(\mathbf{x}(t_k), t_k, h),$$

где $\mathbf{x}(t)$ — точное решение задачи (16). Схема имеет порядок p , если $\|\tau_k\| = O(h^{p+1})$.

Определение 3 (Глобальная погрешность). Глобальная погрешность *после* N шагов равна $e_N = \|\hat{\mathbf{x}}_N - \mathbf{x}(1)\|$. Для L -Липшицева поля скоростей и схемы порядка p выполняется фундаментальная оценка [70, 71]:

$$e_N \leq \frac{Ch^p}{L}(e^L - 1), \quad (17)$$

где константа C зависит от $(p+1)$ -й производной точного решения $\mathbf{x}(t)$.

Оценка (17) классически выводится из дискретной леммы Грёнвалла: при условии $\|\Phi(\mathbf{y}, t, h) - \Phi(\mathbf{z}, t, h)\| \leq L\|\mathbf{y} - \mathbf{z}\|$ и суммировании локальных ошибок τ_k по индукции получается, что $e_N \leq \tau_{\max} \cdot \sum_{k=0}^{N-1} (1 + hL)^k \leq (\tau_{\max}/hL)(e^L - 1)$.

3.7.2 Метод Эйлера

Явный метод Эйлера [72] — простейшая одношаговая схема. Он получается из формулы Тейлора первого порядка:

$$\mathbf{x}(t + h) = \mathbf{x}(t) + h \mathbf{x}'(t) + \frac{h^2}{2} \mathbf{x}''(t) + O(h^3) = \mathbf{x}(t) + h f_{\theta}(\mathbf{x}(t), t) + O(h^2).$$

Отбрасывая члены порядка $O(h^2)$, получаем схему первого порядка:

$$\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + h f_{\theta}(\hat{\mathbf{x}}_k, t_k). \quad (18)$$

Локальная погрешность $\tau_k = O(h^2)$, глобальная — $O(h)$. При $N = 1$ шаг совпадает со всем промежутком $[0, 1]$:

$$\hat{\mathbf{x}}_1 = \mathbf{x}_0 + f_{\theta}(\mathbf{x}_0, 0).$$

Геометрически: метод Эйлера в каждой точке проводит касательную к траектории и движется по ней до следующего узла. Точность определяется тем, насколько “прямой” является истинная траектория — именно это свойство выполнено для флоу матчинга с линейным интерполянтом.

3.7.3 Метод средней точки

Метод средней точки [73] использует оценку производной в середине шага:

$$\mathbf{k}_1 = f_{\theta}(\hat{\mathbf{x}}_k, t_k), \quad \hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + h f_{\theta}\left(\hat{\mathbf{x}}_k + \frac{h}{2} \mathbf{k}_1, t_k + \frac{h}{2}\right). \quad (19)$$

Идея метода — использовать наклон не в начальной точке шага (как в Эйлере), а в его середине: это компенсирует кривизну траектории в первом порядке. Из разложения Тейлора:

$$f_\theta(\mathbf{x} + \frac{h}{2}\mathbf{k}_1, t + \frac{h}{2}) = f_\theta + \frac{h}{2}(\partial_t f_\theta + \mathbf{k}_1^\top \nabla_{\mathbf{x}} f_\theta) + O(h^2) = \mathbf{x}'(t + \frac{h}{2}) + O(h^2),$$

поэтому $\tau_k = O(h^3)$, глобальная погрешность — $O(h^2)$. Цена — два обращения к f_θ на шаг.

3.7.4 Метод Рунге–Кутты 2-го порядка (RK2 / метод Хойна)

Метод Хойна [70] (вариант RK2) строит прогнозирующий шаг методом Эйлера, а затем уточняет по правилу трапеции:

$$\mathbf{k}_1 = f_\theta(\hat{\mathbf{x}}_k, t_k), \quad \mathbf{k}_2 = f_\theta(\hat{\mathbf{x}}_k + h \mathbf{k}_1, t_k + h), \quad \hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + \frac{h}{2}(\mathbf{k}_1 + \mathbf{k}_2). \quad (20)$$

Схема (20) имеет второй порядок точности, требует двух обращений к f_θ за шаг. Идея — использовать среднее наклонов в начальной и (приближённой) конечной точках шага.

3.7.5 Метод Рунге–Кутты 4-го порядка (RK4)

Классический метод Рунге–Кутты 4-го порядка [74] использует четыре вычисления поля скоростей:

$$\begin{aligned} \mathbf{k}_1 &= f_\theta(\hat{\mathbf{x}}_k, t_k), \\ \mathbf{k}_2 &= f_\theta\left(\hat{\mathbf{x}}_k + \frac{h}{2}\mathbf{k}_1, t_k + \frac{h}{2}\right), \\ \mathbf{k}_3 &= f_\theta\left(\hat{\mathbf{x}}_k + \frac{h}{2}\mathbf{k}_2, t_k + \frac{h}{2}\right), \\ \mathbf{k}_4 &= f_\theta(\hat{\mathbf{x}}_k + h \mathbf{k}_3, t_k + h), \\ \hat{\mathbf{x}}_{k+1} &= \hat{\mathbf{x}}_k + \frac{h}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4). \end{aligned} \quad (21)$$

Схема имеет четвёртый порядок точности ($\tau_k = O(h^5)$, $e_N = O(h^4)$). Структура весов задаётся таблицей Бутчера:

0				
1/2	1/2			
1/2	0	1/2		
1	0	0	1	
	1/6	1/3	1/3	1/6

Веса $(1/6, 1/3, 1/3, 1/6)$ соответствуют формуле Симпсона интегрирования $\int_0^1 g(s) ds \approx \frac{1}{6}(g(0) + 4g(1/2) + g(1))$, отсюда и название “симпсоновский RK4”.

3.7.6 Неявные и адаптивные методы (краткий обзор)

Для жёстких систем ОДУ, в которых явные методы требуют экстремально малого шага из-за условий устойчивости, разработаны неявные схемы. Простейшая — *неявный (backward) метод Эйлера*:

$$\hat{\mathbf{x}}_{k+1} = \hat{\mathbf{x}}_k + h f_\theta(\hat{\mathbf{x}}_{k+1}, t_{k+1}),$$

требующая на каждом шаге решения нелинейного уравнения относительно $\hat{\mathbf{x}}_{k+1}$ (методом Ньютона или фиксированной точки). Неявные схемы А-устойчивы: область их устойчивости содержит всю левую полуплоскость. На задачах флоу матчинга, где правая часть f_θ — глубокая нейронная сеть, неявные методы практически неприменимы из-за стоимости итераций Ньютона.

Адаптивные методы (Дорманд–Принс, RK45) подбирают шаг h автоматически по локальной оценке погрешности, сравнивая предсказания схем разного порядка. Они стандарт для общих задач, но в флоу матчинге не дают выигрыша: целевое поле постоянно по t , и любой шаг h обеспечивает идентичную точность с фиксированной сеткой.

3.7.7 Точность при линейном поле скоростей

Утверждение 3 (Точность Эйлера для MFM). Пусть обученная сеть f_θ аппроксимирует истинное поле u_t с равномерной ошибкой $\delta = \sup_{t, \mathbf{x}} \|f_\theta(\mathbf{x}, t) -$

$u_t(\mathbf{x})\|_2$, а u_t является L -Липшицевым по $\mathbf{x}$. Тогда глобальная ошибка метода Эйлера с N шагами ограничена:

$$e_N \leq \frac{\delta}{L}(e^L - 1) + \frac{C_2 h}{2L}(e^L - 1), \quad (22)$$

где $C_2 = \sup_{t,\mathbf{x}} \|\partial_t u_t + (u_t \cdot \nabla) u_t\|_2$ — норма ускорения траектории.

Эскиз. Локальная ошибка состоит из двух слагаемых: $\tau_k = h\delta + \frac{h^2}{2}C_2 + O(h^3)$. Первое — из-за несовершенства аппроксимации сети, второе — стандартный остаток метода Эйлера. Суммирование с применением леммы Грёнвалла даёт (22). $\square$

При линейном интерполянте (7) условная скорость $u_t(\cdot \mid \mathbf{x}_1) = \mathbf{x}_1 - \mathbf{x}_0$ постоянна по t и $\mathbf{x}_t$, поэтому ускорение траектории равно нулю ($C_2 = 0$ в идеале). Следовательно, второе слагаемое в (22) обращается в нуль, и ошибка определяется исключительно качеством аппроксимации сетью δ . Это даёт строгое математическое обоснование тому, что одношаговый Эйлер достаточен. Более того, методы высшего порядка (RK2, RK4) не дают выигрыша при нулевом C_2 , но добавляют несколько вычислений f_θ , что лишь *накапливает* погрешность аппроксимации. Это согласуется с экспериментальным анализом вклада компонент в таблице 7: одношаговый Эйлер показывает наилучший MAE и SSIM среди всех численных схем.

4 Описание предложенного метода

Теория из раздела 3 даёт математическую формулировку задачи и доказывает, что искомое поле скоростей u_t можно обучить симуляционно-свободно, а при линейном интерполянте одного шага метода Эйлера достаточно для численного интегрирования. Настоящий раздел переводит эти результаты в практический алгоритм: фиксируется конкретный класс параметризаций f_θ (архитектура TimeResNet), описывается схема обучения и инференса, и формулируются базовые методы сравнения.

4.1 Общая схема метода MFM

Метод **Medical Flow Matching (MFM)** объединяет три ключевых компонента: (1) предобработку и регистрацию парных КТ-данных, (2) обучение нейронной сети f_θ предсказывать поле скоростей в рамках условного флоу матчинга и (3) инференс через однократное интегрирование ОДУ.

Схема работы метода представлена на рисунке 1. Обучение выполняется следующим образом: для каждой пары $(\mathbf{x}_0, \mathbf{x}_1)$ и случайного времени $t \sim \mathcal{U}[0,1]$ формируется промежуточный образец $\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1$ и целевая скорость $\mathbf{v}_t = \mathbf{x}_1 - \mathbf{x}_0$; сеть f_θ минимизирует ℓ_2 -расстояние между предсказанной и целевой скоростями. При инференсе интегрирование уравнения (1) от $t = 0$ до $t = 1$ даёт синтетический контрастный срез; от $t = 1$ до $t = 0$ — нативный. Единственная сеть обслуживает оба направления, что вдвое сокращает затраты на обучение и хранение весов.

4.2 Условный флоу матчинг

Напомним формальную постановку, опираясь на обозначения раздела 3. Пусть $\pi_0 = \pi_N$ (нативное) и $\pi_1 = \pi_C$ (контрастное) при трансляции в направлении нативное $\rightarrow$ контрастное; роли обмениваются для обратного направления. Линейный интерполянт (7) определяет вероятностный путь $\{\pi_t\}$, а потеря




Рис. 1: Схема обучения и инференса MFM. Сверху: линейная интерполяция между нативным и контрастным срезами при разных значениях t . Снизу: обучение сети предсказывать постоянную скорость $\mathbf{v} = \mathbf{x}_1 - \mathbf{x}_0$.

условного флоу матчинга (6) обучает сеть предсказывать постоянную целевую скорость $\mathbf{x}_1 - \mathbf{x}_0$.

Принципиальное отличие от диффузионных моделей состоит в том, что:

- целевая скорость $\mathbf{v}_t = \mathbf{x}_1 - \mathbf{x}_0$ не зависит от t — сети достаточно выучить одну функцию, а не T различных;
- потеря (6) вычисляется аналитически, без численного интегрирования ОДУ;
- при инференсе достаточно одного шага метода Эйлера, поскольку выученное поле скоростей практически линейно.

Двунаправленная трансляция. Так как линейный интерполянт (7) симметричен по $\mathbf{x}_0$ и $\mathbf{x}_1$, трансляция в обоих направлениях обеспечивается одной сетью простой заменой пределов интегрирования: интегрирование от 0 к 1 выполняет нативное $\rightarrow$ контрастное, от 1 к 0 — контрастное $\rightarrow$ нативное. В процессе обучения пары предъявляются в обоих порядках, что дополнительно

обогащает разнообразие обучающих примеров.

4.3 Архитектура TimeResNet

TimeResNet представляет собой U-Net энкодер–декодер с двумя специализированными модификациями, разработанными применительно к задаче условного флоу матчинга (рисунок 2).




Рис. 2: Архитектура TimeResNet: U-Net с поблочной аффинной временной модуляцией и модулем self-attention на буттлнеке. Единственная сеть используется для обоих направлений трансляции.

4.3.1 (а) Поблочное внедрение временного сигнала

Скалярный параметр $t \in [0, 1]$ кодируется посредством синусоидального позиционного кодирования [14] и преобразуется двухслойным персептроном с активацией SiLU (рисунок 3). На выходе MLP получают векторы $\mathbf{A}, \mathbf{B} \in \mathbb{R}^C$, специфичные для данного ResNet-блока. Скрытая активация $\mathbf{h}$ после первой пары GroupNorm–SiLU–Conv модулируется аффинно:

$$\mathbf{h} \leftarrow \mathbf{A} \odot \mathbf{h} + \mathbf{B}, \quad (23)$$

где $\odot$ — поэлементное умножение с трансляцией по пространственным измерениям.




Рис. 3: Модуль временного эмбединга: синусоидальное кодирование $\rightarrow$ двух-слойный MLP $\rightarrow$ аффинная модуляция (масштаб $\mathbf{A}$, сдвиг $\mathbf{B}$; формула (23)).

Внедрение временного сигнала *в каждый блок* принципиально отличает TimeResNet от наивного подхода, при котором t конкатенируется лишь с входом сети. Следующее утверждение объясняет, почему это различие существенно с точки зрения градиентного сигнала.

Утверждение 4 (Сохранение временного сигнала на всех глубинах). Обозначим скрытые активации в блоках $l = 1, \dots, L$ через $\mathbf{h}_l$, а потерю CFM — через $\mathcal{L}$. Пусть $\mathcal{M}_l(\mathbf{h}_l; t)$ — оператор аффинной временной модуляции в блоке l , определённый формулой (23), с обучаемой проекцией W_l , не сводящейся к нулевой. Тогда:

- (i) При поблочном внедрении на каждой глубине l существует ненулевая компонента градиента по t :

$$\frac{\partial \mathcal{L}}{\partial t} = \sum_{l=1}^L \frac{\partial \mathcal{L}}{\partial \mathbf{h}_l} \cdot \frac{\partial \mathcal{M}_l(\mathbf{h}_l; t)}{\partial t} \neq 0 \quad \text{в общем положении.} \quad (24)$$

- (ii) При наивной конкатенации t только со входом сети ($\mathbf{h}_0 = [\mathbf{x}; t]$) производная по t передаётся в блок l лишь через композицию якобианов всех предшествующих блоков:

$$\frac{\partial \mathbf{h}_l}{\partial t} = \left(\prod_{k=1}^l J_{g_k} \right) \frac{\partial \mathbf{h}_0}{\partial t}, \quad \left\| \frac{\partial \mathbf{h}_l}{\partial t} \right\| \leq \left(\prod_{k=1}^l \|J_{g_k}\| \right) \left\| \frac{\partial \mathbf{h}_0}{\partial t} \right\|, \quad (25)$$

т. е. прямого (независимого от глубины) канала для t не существует, и при $\prod_k \|J_{g_k}\| < 1$ норма $\|\partial \mathbf{h}_l / \partial t\|$ экспоненциально затухает с глубиной (классическая проблема исчезающего градиента).

Доказательство. (i) Применим цепное правило к функционалу $\mathcal{L}(\theta; t)$. Поскольку оператор $\mathcal{M}_l$ зависит от t через коэффициенты $\mathbf{A}_l(t), \mathbf{B}_l(t)$, прямой подсчёт даёт

$$\frac{\partial \mathcal{M}_l(\mathbf{h}_l; t)}{\partial t} = \frac{\partial \mathbf{A}_l}{\partial t} \odot \mathbf{h}_l + \frac{\partial \mathbf{B}_l}{\partial t}, \quad \frac{\partial (\mathbf{A}_l, \mathbf{B}_l)}{\partial t} = W_l \cdot \text{MLP}'(\gamma(t)) \cdot \gamma'(t).$$

Синусоидальное кодирование γ обладает почти всюду ненулевой производной $\gamma'(t)$, а W_l по предположению не сводится к нулю. Поэтому $\partial \mathcal{M}_l / \partial t \neq 0$ почти всюду. Просуммировав по $l = 1, \dots, L$ вклады по цепному правилу, получаем (24).

(ii) При наивной конкатенации сигнал t входит в сеть лишь через $\mathbf{h}_0$. Для последующих блоков $\mathbf{h}_l = g_l(\mathbf{h}_{l-1})$ не зависит от t напрямую, а только

через композицию $\mathbf{h}_l = g_l \circ \dots \circ g_1(\mathbf{h}_0(t))$. По цепному правилу

$$\frac{\partial \mathbf{h}_l}{\partial t} = \prod_{k=1}^l J_{g_k} \cdot \frac{\partial \mathbf{h}_0}{\partial t},$$

где J_{g_k} — якобиан блока g_k ; субмультипликативность операторной нормы даёт оценку (25). Произведение $\prod_k \|J_{g_k}\|$ может экспоненциально затухать с глубиной (классическая проблема исчезающего градиента), и тогда вклад t в глубоких блоках практически теряется. В отличие от поблочного внедрения (24), здесь нет независимого “канала” для t : единственный путь его влияния проходит через всю цепочку якобианов и подвержен затуханию. $\square$

Анализ вклада компонент (раздел 5.11) количественно подтверждает следствие утверждения 4: замена поблочного внедрения входовой конкатенацией приводит к росту MAE на 1.77 HU.

4.3.2 (б) Свёрточный self-attention на боттлнеке

Между двумя боттлнековыми ResNet-блоками вставляется модуль self-attention [75] (рисунок 4). Обозначим вход модуля как $\mathbf{X} \in \mathbb{R}^{C \times H \times W}$, где C — число каналов, H, W — пространственные размеры боттлнека.

Шаг 1: нормализация. Применяется групповая нормировка [76] с $G = 32$ группами по каналам:

$$\tilde{\mathbf{X}} = \text{GroupNorm}_G(\mathbf{X}), \quad \tilde{\mathbf{X}}_{c,h,w} = \gamma_c \frac{\mathbf{X}_{c,h,w} - \mu_g}{\sqrt{\sigma_g^2 + \varepsilon}} + \beta_c, \quad (26)$$

где $g = \lfloor cG/C \rfloor$ — номер группы, μ_g, σ_g^2 — среднее и дисперсия активаций по каналам группы g и всем пространственным позициям, γ_c, β_c — обучаемые масштаб и сдвиг.

Шаг 2: проекции запросов, ключей и значений. Тензор $\tilde{\mathbf{X}}$ преобразуется тремя независимыми свёртками 1×1 в тензоры $\mathbf{Q}, \mathbf{K}, \mathbf{V} \in \mathbb{R}^{C \times H \times W}$ с

обучаемыми ядрами $\mathbf{W}^Q, \mathbf{W}^K, \mathbf{W}^V \in \mathbb{R}^{C \times C}$:

$$\mathbf{Q} = \mathbf{W}^Q * \tilde{\mathbf{X}}, \quad \mathbf{K} = \mathbf{W}^K * \tilde{\mathbf{X}}, \quad \mathbf{V} = \mathbf{W}^V * \tilde{\mathbf{X}}, \quad (27)$$

где $*$ — операция свёртки. Свёртка 1×1 эквивалентна аффинному преобразованию вектора каналов в каждой пространственной позиции независимо.

Шаг 3: развёртывание в последовательность токенов. Пространственные оси объединяются в одну: $N := HW$. Каждая позиция трактуется как отдельный токен, и тензоры приводятся к матрицам $Q, K, V \in \mathbb{R}^{N \times C}$:

$$Q_{n,:} = \mathbf{Q}_{:,h(n),w(n)}, \quad K_{n,:} = \mathbf{K}_{:,h(n),w(n)}, \quad V_{n,:} = \mathbf{V}_{:,h(n),w(n)}, \quad (28)$$

где $(h(n), w(n))$ — линейная развёртка пространственной решётки, $n = 1, \dots, N$.

Шаг 4: масштабированное скалярное произведение. Вычисляется матрица попарных сходств токенов и применяется softmax по строкам:

$$\mathbf{S} = \frac{QK^\top}{\sqrt{C}} \in \mathbb{R}^{N \times N}, \quad \mathbf{A}_{n,m} = \frac{\exp(\mathbf{S}_{n,m})}{\sum_{m'=1}^N \exp(\mathbf{S}_{n,m'})}, \quad (29)$$

$$\text{Attention}(Q, K, V) = \mathbf{A} V \in \mathbb{R}^{N \times C}. \quad (30)$$

Деление на $\sqrt{C}$ — классический трюк [14]: при больших C скалярное произведение $Q_n K_m^\top$ имеет дисперсию порядка C , и без масштабирования аргумент softmax насыщается, обнуляя градиент. Поэлементная стоимость (29)–(30) равна $\mathcal{O}(N^2 C) = \mathcal{O}(H^2 W^2 C)$ — квадратична по числу токенов, но применяется только на буттлнеке, где H, W малы.

Шаг 5: сворачивание и остаточное сложение. Результат (30) сворачивается обратно в форму $C \times H \times W$ обратной развёрткой (28), проецируется выходной свёрткой 1×1 с ядром $\mathbf{W}^O \in \mathbb{R}^{C \times C}$ и прибавляется к исходному входу:

$$\mathbf{Y} = \mathbf{X} + \mathbf{W}^O * \text{Reshape}_{C \times H \times W}(\text{Attention}(Q, K, V)). \quad (31)$$

Остаточное соединение обеспечивает тождественную инициализацию модуля: при $\mathbf{W}^O = 0$ модуль не меняет тензор, что облегчает оптимизацию на ранних эпохах [13].




Рис. 4: Модуль свёрточного self-attention на буттлнеке: GroupNorm $\rightarrow$ 1×1 Conv (Q, K, V) $\rightarrow$ развёртывание $\rightarrow$ масштабированное скалярное произведение (29)–(30) $\rightarrow$ остаточное сложение (31).

Внимание применяется на *наименьшем* пространственном разрешении энкодера, что делает квадратичную по $N = HW$ стоимость (29) разумной. Уточним этот выигрыш формально.

Утверждение 5 (Вычислительная сложность self-attention на буттлнеке). Пусть исходное разрешение входа равно $H \times W$, глубина энкодера — k (количество понижающих этапов с коэффициентом 2 на этап), а на каждом этапе уменьшение происходит независимо по высоте и ширине. Тогда число токенов в буттлнеке

$$N_{\text{bottle}} = \frac{HW}{4^k}, \quad (32)$$

а отношение стоимостей self-attention на буттлнеке и на полном разрешении составляет

$$\frac{\text{Cost}_{\text{bottle}}}{\text{Cost}_{\text{full}}} = \frac{\mathcal{O}(N_{\text{bottle}}^2 C)}{\mathcal{O}((HW)^2 C)} = \frac{1}{4^{2k}}. \quad (33)$$

В частности, при $k = 4$ буттлнековый self-attention примерно в $4^8 = 65\,536$ раз дешевле полноразмерного.

Доказательство. Каждый из k этапов энкодера уменьшает пространственное разрешение в 2 раза по обеим осям, что соответствует уменьшению числа пикселей в $4 = 2^2$ раза. После k этапов имеется $N_{\text{bottle}} = HW/4^k$ токенов — получено (32).

Стоимость стандартного self-attention на множестве из N токенов и размерности признака C доминируется матричным произведением $QK^\top \in \mathbb{R}^{N \times N}$ и его умножением на $V \in \mathbb{R}^{N \times C}$, что в сумме даёт $\mathcal{O}(N^2C)$ операций. Подставив $N = HW$ для полноразмерного варианта и $N = N_{\text{bottle}}$ для буттленекового и поделив, получаем (33).

Численный пример: $k = 4 \Rightarrow 4^{2k} = 4^8 = 65\,536$, что и заявлено. $\square$

В отличие от sliding window Swin [66], предложенный модуль не ограничен фиксированным размером окна и способен захватывать долгодистанционные зависимости во всей карте признаков буттленека — именно это свойство критично при трансляции КТ, где удалённые анатомические структуры (например, сосудистое русло) скоррелированы по контрастности. Удаление этого модуля, согласно анализу вклада компонент (раздел 5.11), ведёт к росту MAE на 1.71 HU.

4.4 Базовые методы сравнения

Для всестороннего сравнения рассматриваются три семейства методов.

Регрессионные сети. Прямолинейное обучение сети g_θ минимизировать ℓ_1 -потерю:

$$\mathcal{L}_{\text{reg}}(\theta) = \mathbb{E}[\|g_\theta(\mathbf{x}_C) - \mathbf{x}_N\|_1].$$

Тестируются четыре архитектуры: UNet [64], SegResNet [65], SwinUNETR [66], UMambaBot [67].

DDPM. Условная диффузионная модель, конкатенирующая исходный срез с зашумлённым целевым и использующая DDIM [68] для ускоренного семпли-

рования. Параметры выбраны так, чтобы обеспечить наилучшее качество с разумным временем инференса.

SMILE. Метод SMILE [1] — метод анатомически-управляемого диффузионного контрастного усиления, оцениваемый с использованием опубликованных авторами весов и рекомендованных настроек.

5 Вычислительные эксперименты

5.1 Данные и предобработка

Ретроспективно собраны 120 исследований брюшной полости (52 561 срез) из трёх больниц. Каждое исследование включает парную нативную и артериальную серии одного пациента. Разбиение по пациентам: 80 / 20 / 20 для обучения, теста и отложенной выборки (held-out). Контрастная серия в каждом случае выравнивалась к нативной с помощью деформируемой регистрации ANTs (SyN с маской тела). Все срезы имеют размер 512×512 пикселей; интенсивности ограничены диапазоном $[-1000, 1000]$ HU и масштабированы в $[-1, 1]$.

Аугментация (MONAI [77]): отражения по осям x/y (50%), повороты на $90^\circ k$, $k \in \{1, 2, 3\}$ (50%), аффинные преобразования (70%; поворот $\pm 45^\circ$, сдвиг ± 102.4 пкс, срезание $\pm 10^\circ$). Интенсивностная аугментация исключена: она нарушает соответствие в единицах HU, необходимое для точной трансляции. Двухэнергетические исследования и серии с рассогласованными начальными координатами или пространственными разрешениями удалены после регистрации.

5.2 Детали обучения

Все модели обучались 30 эпох (кривые потерь выходят на плато до эпохи 20; обучение 60 эпох изменило MAE с 4.25 до 4.21 — в пределах шума). Оптимизатор Adam: $\text{lr} = 2 \times 10^{-5}$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, батч 2 на четырёх GPU NVIDIA RTX 3090 (24 ГБ каждая). Для флоу матчинга время $t \sim \mathcal{U}[0, 1]$ сэмплируется на каждом шаге. Входом сети служит конкатенация $[\mathbf{x}_t, \mathbf{x}_{\text{src}}]$ по каналу.

Динамика обучения показана на рисунках 5–7. TimeResNet сходится быстрее остальных архитектур флоу матчинга и достигает более низкого установившегося значения потери CFM.




Рис. 5: Кривые потерь ℓ_1 на тестовой выборке: регрессионные модели (UNet, SegResNet, SwinUNETR, UMambaBot).




Рис. 6: Кривые потерь CFM на тестовой выборке: модели флоу матчинга (TimeResNet, SegResNet, SwinUNETR, UMambaBot).

5.3 Метрики качества

Все метрики вычисляются на шкале $[-1000, 1000]$ HU. Для пациента p обозначим через $\hat{\mathbf{x}}^{(s)}$ синтезированный срез и $\mathbf{x}^{(s)}$ эталонный ($s = 1, \dots, S_p$ срезов, Ω — множество пикселей среза, $|\Omega| = 512^2$). Итоговые значения — среднее по пациентам среднего по срезам.

Средняя абсолютная ошибка (MAE, $\downarrow$).

$$\text{MAE}(\hat{\mathbf{x}}, \mathbf{x}) = \frac{1}{|\Omega|} \sum_{i \in \Omega} |\hat{x}_i - x_i|. \quad (34)$$

MAE выражается в HU и непосредственно характеризует точность восстановления абсолютных значений плотности тканей. Это особенно важно для КТ,




Рис. 7: Кривая потерь MSE на тестовой выборке: диффузионная модель DDPM.

где диагностические пороги (например, 70 HU для кальцификации) требуют точного численного соответствия.

Среднеквадратическая ошибка и PSNR [78] ($\uparrow$).

$$\text{MSE}(\hat{\mathbf{x}}, \mathbf{x}) = \frac{1}{|\Omega|} \sum_{i \in \Omega} (\hat{x}_i - x_i)^2, \quad (35)$$

$$\text{PSNR}(\hat{\mathbf{x}}, \mathbf{x}) = 10 \log_{10} \left(\frac{\text{MAX}^2}{\text{MSE}(\hat{\mathbf{x}}, \mathbf{x})} \right), \quad \text{MAX} = 2000 \text{ HU}. \quad (36)$$

PSNR логарифмически штрафует большие выбросы сильнее, чем MAE, и удобен для сравнения с результатами других работ.

Структурная схожесть (SSIM [79], $\uparrow$). Для двух патчей $\mathbf{u}$, $\mathbf{v}$ (из нормированных изображений $[0,1]$) SSIM определяется как:

$$\text{SSIM}(\mathbf{u}, \mathbf{v}) = \underbrace{\frac{2\mu_u\mu_v + c_1}{\mu_u^2 + \mu_v^2 + c_1}}_{\text{яркость}} \cdot \underbrace{\frac{2\sigma_u\sigma_v + c_2}{\sigma_u^2 + \sigma_v^2 + c_2}}_{\text{контраст}} \cdot \underbrace{\frac{\sigma_{uv} + c_3}{\sigma_u\sigma_v + c_3}}_{\text{структура}}, \quad (37)$$

где μ_u, μ_v — средние, σ_u^2, σ_v^2 — дисперсии, σ_{uv} — ковариация; стабилизирующие константы $c_1 = (0.01)^2$, $c_2 = (0.03)^2$, $c_3 = c_2/2$. Итоговый $\text{SSIM}(\hat{\mathbf{x}}, \mathbf{x})$ есть среднее по всем патчам скользящего окна 11×11 .

Коэффициент Дайса (Dice, $\uparrow$). При оценке качества downstream-сегментации используется:

$$\text{Dice}(A, B) = \frac{2|A \cap B|}{|A| + |B|}, \quad (38)$$

где A — предсказанная маска, B — эталонная.

TotalSeg-LPIPS ($\downarrow$). Перцептивное расстояние вычисляется с медицинским энкодером TotalSegmentator в режиме 2D (по срезам) и 3D (учитывающем межсрезовую согласованность в объёмном кубе). Метрика аналогична LPIPS, но использует признаки, обученные на медицинских данных, что делает её более релевантной для КТ, чем стандартный ImageNet-LPIPS.

5.4 Результаты: контрастное $\rightarrow$ нативное

В таблице 1 приведены регрессионные базовые линии, в таблице 2 — флоу матчинг и диффузионные методы (одношаговый Эйлер).

Таблица 1: Регрессионные базовые линии (контрастное $\rightarrow$ нативное). Среднее $\pm$ ст. откл. по пациентам; лучший — **жирный**, второй — подчёркнутый.

Модель	Тест			Held-out			Время, с	Пар., М
	MAE $\downarrow$	SSIM $\uparrow$	PSNR $\uparrow$	MAE $\downarrow$	SSIM $\uparrow$	PSNR $\uparrow$		
UNet	8.21 $\pm$ 1.14	.975 $\pm$.005	36.06 $\pm$ 1.78	7.24 $\pm$ 1.01	.978 $\pm$.007	37.81 $\pm$ 1.67	0.007	104.3
SegResNet	7.27$\pm$1.00	.979$\pm$.005	36.31$\pm$1.71	6.33$\pm$1.03	.982$\pm$.007	38.46$\pm$1.70	<u>0.055</u>	214.1
SwinUNETR	7.55 $\pm$ 0.98	.978 $\pm$.005	<u>36.27$\pm$1.78</u>	6.67 $\pm$ 0.97	.981 $\pm$.007	38.25 $\pm$ 1.66	0.084	120.1
UMambaBot	<u>7.32$\pm$1.01</u>	<u>.978$\pm$.005</u>	36.24 $\pm$ 1.76	<u>6.37$\pm$1.01</u>	.982$\pm$.007	<u>38.30$\pm$1.64</u>	0.075	141.6

MFM превосходит лучший регрессионный базовый метод (SegResNet) на 2.1 HU по MAE и на 0.012 по SSIM на held-out. По сравнению со SMILE выигрыш по MAE составляет **7.1 $\times$** . SMILE применялся в режиме zero-shot:

Таблица 2: Флоу матчинг и диффузионные методы (контрастное $\rightarrow$ нативное, Эйлер 1 шаг).

Метод / Модель	Тест			Held-out			Время, с	Пар., М
	MAE↓	SSIM↑	PSNR↑	MAE↓	SSIM↑	PSNR↑		
Диффузионные методы								
DDPM	17.82±1.81	.935±.009	30.19±1.62	18.20±1.39	.934±.008	30.05±1.48	44.2	124.7
SMILE [1]	30.35±5.26	.892±.032	26.75±1.43	30.22±4.95	.887±.026	26.70±1.33	9.03	1066
Флоу матчинг (Эйлер, 1 шаг)								
SegResNet	8.00±0.99	.977±.005	36.50±1.82	7.23±1.07	.979±.007	38.45±1.65	0.065	214.1
UMambaBot	8.15±1.09	.976±.005	36.23±1.75	7.29±1.00	.979±.007	38.14±1.59	0.091	141.6
SwinUNETR	8.19±1.03	.976±.005	36.28±1.73	7.42±0.98	.979±.007	38.11±1.57	0.107	120.1
MFM (TimeResNet)	5.14±0.99	.991±.005	40.18±1.77	4.25±1.09	.994±.007	42.19±1.67	0.125	124.7

опубликованные веса разворачивались с рекомендованными настройками на нашем датасете — стандартный способ оценки готовой модели на новой когорте.

5.5 Результаты: нативное $\rightarrow$ контрастное

В таблице 3 приведены результаты в обратном направлении. Те же веса, никакого дополнительного обучения — это подтверждает теоретический вывод о двунаправленности метода (раздел 3).

Таблица 3: Флоу матчинг и SMILE (нативное $\rightarrow$ контрастное, held-out).

Метод / Модель	Тест			Held-out		
	MAE↓	SSIM↑	PSNR↑	MAE↓	SSIM↑	PSNR↑
SMILE [1]	20.37±4.21	.909±.025	30.04±2.06	21.70±4.26	.903±.019	29.28±1.53
SegResNet	<u>7.81±0.95</u>	<u>.980±.004</u>	<u>35.99±1.57</u>	<u>6.82±0.82</u>	<u>.983±.004</u>	<u>37.82±1.46</u>
UMambaBot	8.14±0.99	.979±.004	35.93±1.54	7.23±0.84	.982±.005	37.50±1.31
SwinUNETR	8.21±0.97	.979±.004	35.94±1.57	7.36±0.78	.982±.004	37.52±1.32
MFM (TimeResNet)	5.60±0.99	.993±.004	39.69±1.60	4.57±0.87	.996±.004	41.52±1.53

5.6 Клиническая значимость: MAE по анатомическим структурам

Помимо среднего по всему срезу, оценим точность трансляции на клинически значимых структурах. Маски аорты, почек, печени и поджелудочной железы получены с помощью TotalSegmentator на эталонных нативных сканах 20 held-out пациентов. MAE вычислялся внутри каждой маски.

Таблица 4: MAE по анатомическим структурам (HU, held-out, среднее $\pm$ ст. откл. по пациентам). Лучший — **жирный**.

Метод	Аорта	Почки	Печень	Поджелудочная	Весь срез
<i>Контрастное $\rightarrow$ нативное</i>					
SegResNet (regression)	23.69 $\pm$ 25.05	21.77 $\pm$ 26.90	13.10 $\pm$ 5.56	17.57 $\pm$ 9.87	6.33
SMILE [1]	168.5 $\pm$ 79.6	96.5 $\pm$ 56.8	97.1 $\pm$ 24.3	92.2 $\pm$ 42.2	30.22
MFM (TimeResNet)	16.92$\pm$16.28	16.41$\pm$19.75	9.79$\pm$4.76	12.65$\pm$7.89	4.25
<i>Нативное $\rightarrow$ контрастное</i>					
SMILE [1]	295.8 $\pm$ 72.2	177.9 $\pm$ 56.7	63.0 $\pm$ 12.1	121.5 $\pm$ 39.7	21.70
MFM (TimeResNet)	20.08$\pm$19.63	24.29$\pm$19.15	12.80$\pm$7.22	15.43$\pm$7.83	4.57

Разрыв концентрируется на контраст-чувствительных структурах: при синтезе контраста (N $\rightarrow$ C) MFM обеспечивает MAE на **15 $\times$ ниже**, чем SMILE, на уровне аорты. Большие стандартные отклонения у SegResNet и SMILE объясняются систематическими промахами на отдельных пациентах, тогда как у MFM они умеренны.

5.7 Перцептивное качество: TotalSeg-LPIPS

В дополнение к пиксельным метрикам вычислено перцептивное расстояние на основе медицинского энкодера — TotalSegmentator-LPIPS: 2D-вариант измеряет качество отдельных срезов, 3D-вариант учитывает межсрезовую согласованность в объёмном кубе.

MFM достигает наименьшего перцептивного расстояния как в 2D, так и в 3D, что свидетельствует о сохранении тонкой анатомической структуры.

Таблица 5: Перцептивное расстояние TotalSeg-LPIPS (контрастное $\rightarrow$ нативное, held-out). $\downarrow$ лучше.

Метод	2D-LPIPS _{TotalSeg} $\downarrow$	3D-LPIPS _{TotalSeg} $\downarrow$
SegResNet	0.158 $\pm$ 0.051	0.012 $\pm$ 0.005
SMILE [1]	0.704 $\pm$ 0.144	0.096 $\pm$ 0.044
MFM (TimeResNet)	0.138$\pm$0.053	0.007$\pm$0.004

3D-метрика подтверждает межсрезовую согласованность синтеза, несмотря на то что сеть обрабатывает срезы независимо.

5.8 Сравнение с ускоренным сэмплером DDIM

Тезис о «350-кратном ускорении» относится к сравнению с полным DDPM (1000 шагов). Для честного сравнения с современными быстрыми сэмплерами проведено дополнительное измерение с DDIM-50 — стандартным быстрым методом для условных DDPM.

Таблица 6: MFM против DDPM и DDIM-50 (контрастное $\rightarrow$ нативное, held-out).

Метод	Шагов	MAE $\downarrow$	SSIM $\uparrow$	Время/срез	к MFM
DDPM (полный)	1000	18.20 $\pm$ 1.39	0.934	44.20 с	354 $\times$ медл.
DDIM-50	50	21.07 $\pm$ 1.61	0.815	5.03 с	40 $\times$ медл.
MFM (Эйлер-1)	1	4.25$\pm$1.09	0.994	0.125 с	1 $\times$

Даже с ускоренным сэмплером DDIM-50 диффузионная модель остаётся в **40 раз медленнее** и в **5 раз хуже** по MAE. Важно, что SSIM DDIM-50 деградирует на 18 пунктов относительно полного DDPM — быстрый сэмплер снижает не только время, но и качество. MFM объединяет скорость и качество в одном шаге, что согласуется с теоретическим аргументом о малой кривизне траекторий (раздел 3).

5.9 Одношаговый инференс: теория и эксперимент

В таблице 7 сравниваются численные схемы интегрирования для TimeResNet. Одношаговый метод Эйлера обеспечивает наилучший MAE и SSIM. Методы высшего порядка (RK2, RK4, средняя точка) незначительно ухудшают показатели, что согласуется с оценкой (22): при малой кривизне выученного поля скоростей Эйлер практически точен, а дополнительные вычисления поля в RK4 лишь накапливают ошибку аппроксимации.

Таблица 7: Анализ вклада компонент: численные методы интегрирования ОДУ для MFM (контрастное $\rightarrow$ нативное). *Вычисл.* = число обращений к сети.

Метод (шагов)	Тест			Held-out			Вычисл.
	MAE↓	SSIM↑	PSNR↑	MAE↓	SSIM↑	PSNR↑	
Эйлер (1)	5.14±0.99	.991±.005	<u>40.18±1.77</u>	4.25±1.09	.994±.007	42.19±1.67	1
Эйлер (2)	<u>5.17±1.05</u>	<u>.990±.006</u>	40.21±1.86	<u>4.35±1.07</u>	<u>.993±.007</u>	<u>42.17±1.66</u>	2
Эйлер (3)	5.32±1.07	.989±.006	40.04±1.87	4.50±1.09	.991±.008	42.00±1.64	3
RK2 (1)	5.53±1.04	.989±.005	39.95±1.78	4.68±1.01	.992±.007	41.81±1.56	2
RK4 (1)	5.80±1.17	.985±.007	39.84±1.82	5.05±1.14	.987±.009	41.61±1.56	4
Средняя точка (1)	5.79±1.18	.985±.007	39.70±1.79	5.00±1.14	.988±.009	41.54±1.57	2

5.10 Двухнаправленность: теория vs. эксперимент

Из теоремы 1 и симметрии линейного интерполянта (7) следует, что один и тот же минимизатор потери (13) обслуживает оба направления трансляции. Для экспериментальной проверки этого утверждения обучен однонаправленный вариант TimeResNet по протоколу, идентичному двухнаправленному.

Таблица 8: Двухнаправленный MFM против однонаправленного TimeResNet (контрастное $\rightarrow$ нативное, held-out).

Вариант	MAE↓	SSIM↑	PSNR↑	Параметры
Однонаправленный TimeResNet	4.22±0.98	0.994±0.008	42.29±1.62	124.7 М
Двухнаправленный MFM	4.25±1.09	0.994±0.007	42.19±1.67	124.7 М

Различие находится в пределах шума обучения, что подтверждает теоретическое предсказание: при линейном интерполянте двунаправленность не несёт никакого штрафа по качеству, одновременно вдвое снижая стоимость обучения и хранения.

5.11 Анализ вклада компонент архитектуры TimeResNet

Таблица 9: Анализ вклада компонент TimeResNet (held-out, Эйлер 1 шаг, контрастное $\rightarrow$ нативное).

Вариант	MAE↓	SSIM↑	PSNR↑
TimeResNet (полная)	4.25±1.09	.994±.007	42.19±1.67
без self-attention на буттлнеке	5.96±1.01	.985±.007	39.84±1.66
без поблочного временного внедрения	6.02±1.01	.987±.007	39.96±1.71
без обоих компонентов	6.67±1.07	.981±.007	38.52±1.65

Удаление буттлнекового self-attention ухудшает MAE на 1.71 HU, удаление поблочного временного внедрения — на 1.77 HU. Совместное удаление даёт 2.42 HU — больше суммы, что говорит о синергии компонентов.

5.12 Межосевая согласованность

Одна из потенциальных слабостей 2D-обработки — возможные несогласованности между срезами в сагиттальной и корональной проекциях. Таблица 10 сводит SSIM по трём осям. Величина $\Delta = \text{SSIM}_{\text{axial}} - \overline{\text{SSIM}}_{\perp}$ характеризует межосевую рассогласованность.

Значение $\Delta = 0.0001$ у MFM фактически равно нулю: несмотря на 2D-обработку, синтез пространственно согласован во всех трёх проекциях. Это согласуется с результатами 3D-TotalSeg-LPIPS (таблица 5).

Таблица 10: SSIM по трём проекциям (контрастное $\rightarrow$ нативное, held-out). Δ = аксиальный минус среднее двух поперечных.

Метод	Аксиальный	Корональный	Сагиттальный	$\Delta \downarrow$
SegResNet	0.974	0.973	0.974	0.0003
SMILE [1]	0.852	0.848	0.847	0.0047
MFM (TimeResNet)	0.984	0.985	0.983	0.0001

5.13 Качественный анализ




Рис. 8: Визуальное сравнение методов (контрастное $\rightarrow$ нативное). Сверху вниз: SegResNet, DDPM, MFM, эталон нативный, вход контрастный. Справа — карты абсолютных отклонений.

SMILE демонстрирует наибольшие отклонения и пространственные сме-




Рис. 9: Расширенное сравнение в аксиальной, сагиттальной и корональной проекциях с картами разностей. Сверху вниз: регрессионные варианты, DDPM, варианты флоу матчинга, эталон, вход.

щения в сагиттальной и корональной плоскостях. DDPM страдает от систематических межсрезовых несогласованностей, проявляющихся в виде ярких полос на разностных картах. Регрессия (SegResNet) избегает смещений, но вносит избыточное размытие. MFM сохраняет пространственную согласованность во всех трёх проекциях и одновременно воспроизводит чёткие тканевые границы: карты разностей равномерно тёмные.

5.14 Применимость для задачи сегментации

На аорте 20 held-out пациентов размечены нативные и контрастные срезы. Контрастные изображения транслированы MFM в нативные. Обучены две модели nnUNet v2 [69], валидация — на 20 дополнительных нативных сканах:

- **Реальные нативные:** Dice = **0.966**;
- **MFM-сгенерированные нативные:** Dice = **0.926** (95.9% от базового уровня).

Разрыв в 4 процентных пункта подтверждает, что синтезированные изображения сохраняют анатомическую информацию, достаточную для обучения сегментационных моделей. Практические сценарии применения: (i) трансляция доступной модальности для обучения на недостающей; (ii) удвоение обучающей выборки за счёт двунаправленной трансляции.

6 Заключение

В данной выпускной квалификационной работе математическая задача переноса вероятностной меры $T_{\#}\pi_N = \pi_C$ для распределений нативных и контрастных КТ-изображений исследована средствами теории условного флоу матчинга. Показано, что при линейном интерполянте (7) соответствующее условное поле скоростей постоянно по времени, кривизна траектории нулевая, а кинетическая энергия минимальна по Бенаму–Бренье. Это даёт теоретическое обоснование одношагового численного интегрирования (§3.7) и симметрии единственной сети для обоих направлений трансляции (§3). Практической реализацией служит **Medical Flow Matching (MFM)** — конвейер обучения и инференса, а параметризацией поля скоростей — предложенная архитектура **TimeResNet** (U-Net с поблочной аффинной модуляцией временного сигнала и свёрточным self-attention на буттлнеке).

Итоги работы. *Теоретические результаты.* Из симметрии линейного интерполянта следует, что единственная сеть обеспечивает трансляцию в обоих направлениях без штрафа по качеству — экспериментально подтверждено разницей 0.03 HU между двунаправленным и однонаправленным вариантами (таблица 8). Оценка ошибки метода Эйлера (22) объясняет, почему одношаговый инференс достаточен: кривизна выученного поля мала при линейном интерполянте.

Качество реконструкции. На отложенной выборке MFM достигает $\text{MAE} = 4.25 \text{ HU}$, $\text{SSIM} = 0.994$, $\text{PSNR} = 42.19 \text{ дБ}$ — лучших значений среди всех рассмотренных методов. По сравнению со SMILE MAE ниже в 7.1 раза. На клинически значимых структурах разрыв ещё значительнее: на аорте при трансляции нативное $\rightarrow$ контрастное MFM обеспечивает MAE в 15 раз ниже, чем SMILE.

Скорость и эффективность. Даже в честном сравнении с ускоренным сэмплером DDIM-50 MFM работает в 40 раз быстрее (0.125 с против 5.03 с) и в 5 раз точнее по MAE. При этом DDIM-50 деградирует по SSIM относительно

полного DDPM.

Межосевая согласованность. Несмотря на 2D-обработку, Δ -SSIM MFM равен 0.0001 — фактически нулевая межосевая рассогласованность, что подтверждается метрикой 3D-TotalSeg-LPIPS = 0.007.

Практическая применимость. nnUNet v2, обученный на MFM-переведённых нативных сканах, достигает Dice = 0.926 против 0.966 на реальных данных — потеря лишь в 4 процентных пункта.

Список литературы

- [1] Junqi Liu, Zejun Wu, Pedro RAS Bassi, Xinze Zhou, Wenxuan Li, Ibrahim E Hamamci, Sezgin Er, Tianyu Lin, Yi Luo, Bjoern Menze, et al. See more, change less: Anatomy-aware diffusion for contrast enhancement. *arXiv preprint arXiv:2512.07251*, 2025.
- [2] Vladimir N. Vapnik. *The Nature of Statistical Learning Theory*. Springer, New York, 1999.
- [3] Trevor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer, 2 edition, 2009.
- [4] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. Deep learning. *Nature*, 521(7553):436–444, 2015.
- [5] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [6] George Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals, and Systems*, 2(4):303–314, 1989.
- [7] Kurt Hornik, Maxwell Stinchcombe, and Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.
- [8] Moshe Leshno, Vladimir Ya. Lin, Allan Pinkus, and Shimon Schocken. Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. *Neural Networks*, 6(6):861–867, 1993.
- [9] Herbert Robbins and Sutton Monroe. A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407, 1951.
- [10] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *ICLR*, 2015.

- [11] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323(6088):533–536, 1986.
- [12] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *NeurIPS*, 2012.
- [13] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016.
- [14] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. *Advances in neural information processing systems*, 30, 2017.
- [15] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *NAACL-HLT*, 2019.
- [16] Diederik P. Kingma and Max Welling. Auto-encoding variational Bayes. In *ICLR*, 2014.
- [17] Danilo Jimenez Rezende, Shakir Mohamed, and Daan Wierstra. Stochastic backpropagation and approximate inference in deep generative models. In *ICML*, 2014.
- [18] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In *NeurIPS*, 2014.
- [19] Martin Arjovsky, Soumith Chintala, and Léon Bottou. Wasserstein generative adversarial networks. In *ICML*, 2017.
- [20] Jascha Sohl-Dickstein, Eric A. Weiss, Niru Maheswaranathan, and Surya Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *ICML*, 2015.

- [21] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- [22] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *ICLR*, 2021.
- [23] Aapo Hyvärinen. Estimation of non-normalized statistical models by score matching. *JMLR*, 6:695–709, 2005.
- [24] Pascal Vincent. A connection between score matching and denoising autoencoders. *Neural Computation*, 23(7):1661–1674, 2011.
- [25] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- [26] Michael S Albergo and Eric Vanden-Eijnden. Building normalizing flows with stochastic interpolants. *arXiv preprint arXiv:2209.15571*, 2022.
- [27] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. In *ICLR*, 2023.
- [28] Cédric Villani. *Optimal Transport: Old and New*, volume 338 of *Grundlehren der mathematischen Wissenschaften*. Springer, 2008.
- [29] Jean-David Benamou and Yann Brenier. A computational fluid mechanics solution to the Monge-Kantorovich mass transfer problem. *Numerische Mathematik*, 84(3):375–393, 2000.
- [30] Yann Brenier. Polar factorization and monotone rearrangement of vector-valued functions. *Communications on Pure and Applied Mathematics*, 44(4):375–417, 1991.

- [31] Rebecca Smith-Bindman, Philip W. Chu, Hana Azman Firdaus, Carly Stewart, Matthew Malekheadayat, Susan Alber, Wesley E. Bolch, Malini Mahendra, Amy Berrington de González, and Diana L. Miglioretti. Projected lifetime cancer risks from current computed tomography imaging. *JAMA Internal Medicine*, 04 2025. ISSN 2168-6106. doi:[10.1001/jamainternmed.2025.0505](https://doi.org/10.1001/jamainternmed.2025.0505). URL <https://doi.org/10.1001/jamainternmed.2025.0505>.
- [32] William W. Mayo-Smith, Julie H. Song, Giles L Boland, Isaac R. Francis, Gary M. Israel, Peter J. Mazzaglia, Lincoln L Berland, and Pari V Pandharipande. Management of incidental adrenal masses: A white paper of the acr incidental findings committee. *Journal of the American College of Radiology : JACR*, 14 8:1038–1044, 2017. URL <https://api.semanticscholar.org/CorpusID:4486169>.
- [33] Wenxuan Li, Chongyu Qu, Xiaoxi Chen, Pedro RAS Bassi, Yijia Shi, Yuxiang Lai, Qian Yu, Huimin Xue, Yixiong Chen, Xiaorui Lin, et al. Abdomenatlas: A large-scale, detailed-annotated, & multi-center dataset for efficient transfer learning and open algorithmic benchmarking. *Medical Image Analysis*, 97: 103285, 2024.
- [34] Qasim Ali Rao and Jeffrey H. Newhouse. Risk of nephropathy after intravenous administration of contrast material: A critical literature analysis. *Radiology*, 239(2):392–397, 2006. doi:[10.1148/radiol.2392050413](https://doi.org/10.1148/radiol.2392050413). URL <https://doi.org/10.1148/radiol.2392050413>. PMID: 16543592.
- [35] Jungye Kim, Jimin Lee, Bitbyeol Kim, Sangwook Kim, Hyeongmin Jin, and Seongmoon Jung. Generation of deep learning based virtual non-contrast ct using dual-layer dual-energy ct and its application to planning ct for radiotherapy. *PLOS ONE*, 19, 12 2024. doi:[10.1371/journal.pone.0316099](https://doi.org/10.1371/journal.pone.0316099).
- [36] Shengye Hu, Baiying Lei, Shuqiang Wang, Yong Wang, Zhiguang Feng, and Yanyan Shen. Bidirectional mapping generative adversarial networks for brain

- mr to pet synthesis. *IEEE Transactions on Medical Imaging*, 41(1):145–157, 2021.
- [37] Reza Kalantar, Sumeet Hindocha, Benjamin Hunter, Bhupinder Sharma, Nasir Khan, Dow-Mu Koh, Merina Ahmed, Eric Aboagye, Richard Lee, and Matthew Blackledge. Non-contrast ct synthesis using patch-based cycle-consistent generative adversarial network (cycle-gan) for radiomics and deep learning in the era of covid-19. *Scientific Reports*, 13, 06 2023. doi:[10.1038/s41598-023-36712-1](https://doi.org/10.1038/s41598-023-36712-1).
 - [38] Jonghun Kim and Hyunjin Park. Adaptive latent diffusion model for 3d medical image to image translation: Multi-modal magnetic resonance imaging study. In *Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision*, pages 7604–7613, 2024.
 - [39] Milad Yazdani, Yasamin Medghalchi, Pooria Ashrafi, Ilker Hacihaliloglu, and Dena Shahriari. Flow matching for medical image synthesis: Bridging the gap between speed and quality. *arXiv preprint arXiv:2503.00266*, 2025.
 - [40] Hadrien Reynaud, Alberto Gomez, Paul Leeson, Qingjie Meng, and Bernhard Kainz. Echoflow: A foundation model for cardiac ultrasound image and video generation. *arXiv preprint arXiv:2503.22357*, 2025.
 - [41] Berengère Aubert-Broche, Mark Griffin, G Bruce Pike, Alan C Evans, and D Louis Collins. Twenty new digital brain phantoms for creation of validation image data bases. *IEEE transactions on medical imaging*, 25(11):1410–1416, 2006.
 - [42] W Paul Segars, G Sturgeon, S Mendonca, Jason Grimes, and Benjamin MW Tsui. 4d xcat phantom for multimodality imaging research. *Medical physics*, 37(9):4902–4915, 2010.
 - [43] T.F. Cootes, G.J. Edwards, and C.J. Taylor. Active appearance models. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 23(6):681–685, 2001. doi:[10.1109/34.927467](https://doi.org/10.1109/34.927467).

- [44] Wen Wei, Emilie Poirion, Benedetta Bodini, Stanley Durrleman, Nicholas Ayache, Bruno Stankoff, and Olivier Colliot. Predicting pet-derived demyelination from multimodal mri using sketcher-refiner adversarial training for multiple sclerosis. *Medical Image Analysis*, 58:101546, 2019. ISSN 1361-8415. doi:<https://doi.org/10.1016/j.media.2019.101546>. URL <https://www.sciencedirect.com/science/article/pii/S1361841519300817>.
- [45] Jin Zhang, Xiaohai He, Linbo Qing, Feng Gao, and Bin Wang. Bpgan: Brain pet synthesis from mri using generative adversarial network for multi-modal alzheimer’s disease diagnosis. *Computer Methods and Programs in Biomedicine*, 217:106676, 2022. ISSN 0169-2607. doi:<https://doi.org/10.1016/j.cmpb.2022.106676>. URL <https://www.sciencedirect.com/science/article/pii/S016926072200061X>.
- [46] Yan Wang, Yanmei Luo, Chen Zu, Bo Zhan, Zhengyang Jiao, Xi Wu, Jiliu Zhou, Dinggang Shen, and Luping Zhou. 3d multi-modality transformer-gan for high-quality pet reconstruction. *Medical Image Analysis*, 91:102983, 2024. ISSN 1361-8415. doi:<https://doi.org/10.1016/j.media.2023.102983>. URL <https://www.sciencedirect.com/science/article/pii/S1361841523002438>.
- [47] Haoyu Lan, the Alzheimer Disease Neuroimaging Initiative, Arthur W. Toga, and Farshid Sepehrband. Three-dimensional self-attention conditional gan with spectral normalization for multimodal neuroimaging synthesis. *Magnetic Resonance in Medicine*, 86(3):1718–1733, 2021. doi:<https://doi.org/10.1002/mrm.28819>. URL <https://onlinelibrary.wiley.com/doi/abs/10.1002/mrm.28819>.
- [48] Chi-Hieu Pham, Carlos Tor-Díez, Hélène Meunier, Nathalie Bednarek, Ronan Fablet, Nicolas Passat, and François Rousseau. Multiscale brain mri super-resolution using deep 3d convolutional networks. *Computerized Medical Imaging and Graphics*, 77:101647, 2019.
- [49] Chenyu You, Guang Li, Yi Zhang, Xiaoliu Zhang, Hongming Shan, Mengzhou

- Li, Shenghong Ju, Zhen Zhao, Zhuiyang Zhang, Wenxiang Cong, et al. Ct super-resolution gan constrained by the identical, residual, and cycle learning ensemble (gan-circle). *IEEE transactions on medical imaging*, 39(1):188–203, 2019.
- [50] Cheng Peng, Pengfei Guo, S Kevin Zhou, Vishal M Patel, and Rama Chellappa. Towards performant and reliable undersampled mr reconstruction via diffusion model sampling. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 623–633. Springer, 2022.
- [51] Yutong Xie and Quanzheng Li. Measurement-conditioned denoising diffusion probabilistic model for under-sampled medical image reconstruction. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 655–664. Springer, 2022.
- [52] Robin Rombach, Andreas Blattmann, Dominik Lorenz, Patrick Esser, and Björn Ommer. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 10684–10695, 2022.
- [53] Alicia Durrer, Julia Wolleb, Florentin Bieder, Tim Sinnecker, Matthias Weigel, Robin Sandkühler, Cristina Granziera, Özgür Yaldizli, and Philippe C Cattin. Diffusion models for contrast harmonization of magnetic resonance images. *arXiv preprint arXiv:2303.08189*, 2023.
- [54] Robert Graf, Joachim Schmitt, Sarah Schlaeger, Hendrik Kristian Möller, Vasiliki Sideri-Lampretsa, Anjany Sekuboyina, Sandro Manuel Krieg, Benedikt Wiestler, Bjoern Menze, Daniel Rueckert, et al. Denoising diffusion-based mri to ct image translation enables automated spinal segmentation. *European Radiology Experimental*, 7(1):70, 2023.
- [55] Pengfei Guo, Can Zhao, Dong Yang, Ziyue Xu, Vishwesh Nath, Yucheng Tang, Benjamin Simon, Mason Belue, Stephanie Harmon, Baris Turkbey, et al. Maisi:

- Medical ai for synthetic imaging. In *2025 IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 4430–4441. IEEE, 2025.
- [56] Lingting Zhu, Zeyue Xue, Zhenchao Jin, Xian Liu, Jingzhen He, Ziwei Liu, and Lequan Yu. Make-a-volume: Leveraging latent diffusion models for cross-modality 3d brain mri synthesis. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 592–601. Springer, 2023.
- [57] Shaoyan Pan, Zach Eidex, Mojtaba Safari, Richard Qiu, and Xiaofeng Yang. Cycle-guided denoising diffusion probability model for 3d cross-modality mri synthesis. In *Medical Imaging 2025: Clinical and Biomedical Imaging*, volume 13410, pages 515–522. SPIE, 2025.
- [58] Mayur K Virarkar, Sai Swarupa R Vulasala, Anjali Verma Gupta, DheerajReddy Gopireddy, Sindhu Kumar, Mauricio Hernandez, Chandana Lall, and Priya Bhosale. Virtual non-contrast imaging in the abdomen and the pelvis: An overview. *Seminars in Ultrasound, CT and MRI*, 43(4):293–310, 2022. ISSN 0887-2171. doi:<https://doi.org/10.1053/j.sult.2022.03.004>. URL <https://www.sciencedirect.com/science/article/pii/S0887217122000312>. Dual source CT: Applications, Technology.
- [59] Shaoyan Pan, Elham Abouei, Jacob Wynne, Chih-Wei Chang, Tonghe Wang, Richard LJ Qiu, Yuheng Li, Junbo Peng, Justin Roper, Pretesh Patel, et al. Synthetic ct generation from mri using 3d transformer-based denoising diffusion model. *Medical Physics*, 51(4):2538–2548, 2024.
- [60] Leonid V. Kantorovich. On the translocation of masses. *Doklady Akademii Nauk SSSR*, 37:227–229, 1942.
- [61] Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David Duvenaud. Neural ordinary differential equations. In *NeurIPS*, 2018.
- [62] Will Grathwohl, Ricky T. Q. Chen, Jesse Bettencourt, Ilya Sutskever, and

- David Duvenaud. FFJORD: Free-form continuous dynamics for scalable reversible generative models. In *ICLR*, 2019.
- [63] Alexander Tong, Kilian Fatras, Nikolay Malkin, Guillaume Huguet, Yanlei Zhang, Jarrod Rector-Brooks, Guy Wolf, and Yoshua Bengio. Improving and generalizing flow-based generative models with minibatch optimal transport. *arXiv preprint arXiv:2302.00482*, 2023.
- [64] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention*, pages 234–241. Springer, 2015.
- [65] Andriy Myronenko. 3d mri brain tumor segmentation using autoencoder regularization. In *International MICCAI brainlesion workshop*, pages 311–320. Springer, 2018.
- [66] Ali Hatamizadeh, Vishwesh Nath, Yucheng Tang, Dong Yang, Holger R Roth, and Daguang Xu. Swin unetr: Swin transformers for semantic segmentation of brain tumors in mri images. In *International MICCAI brainlesion workshop*, pages 272–284. Springer, 2021.
- [67] Jun Ma, Feifei Li, and Bo Wang. U-mamba: Enhancing long-range dependency for biomedical image segmentation. *arXiv preprint arXiv:2401.04722*, 2024.
- [68] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*, 2020.
- [69] Fabian Isensee, Tassilo Wald, Constantin Ulrich, Michael Baumgartner, Saikat Roy, Klaus Maier-Hein, and Paul F Jaeger. nnu-net revisited: A call for rigorous validation in 3d medical image segmentation. In *International Conference on Medical Image Computing and Computer-Assisted Intervention*, pages 488–498. Springer, 2024.

- [70] C. Runge. Ueber die numerische auflösung von differentialgleichungen. *Mathematische Annalen*, 46:167–178, 1895. URL <http://eudml.org/doc/157756>.
- [71] Ernst Hairer, Syvert P. Nørsett, and Gerhard Wanner. *Solving Ordinary Differential Equations I: Nonstiff Problems*. Springer, 2 edition, 1993.
- [72] L. Euler. *Institutionum calculi integralis*. Impensis Academiae Imperialis Scientiarum, 1769. URL <https://books.google.ru/books?id=XmsCrgEACAAJ>.
- [73] Mark Lotkin. A note on the midpoint method of integration. *J. ACM*, 3(3):208–211, July 1956. ISSN 0004-5411. doi:10.1145/320831.320840. URL <https://doi.org/10.1145/320831.320840>.
- [74] W. Kutta. *Beitrag zur näherungsweise Integration totaler Differentialgleichungen*. Teubner, 1901. URL <https://books.google.ru/books?id=K5e6kQEACAAJ>.
- [75] Baosong Yang, Longyue Wang, Derek F. Wong, Lidia S. Chao, and Zhaopeng Tu. Convolutional self-attention networks. In Jill Burstein, Christy Doran, and Thamar Solorio, editors, *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, pages 4040–4045, Minneapolis, Minnesota, June 2019. Association for Computational Linguistics. doi:10.18653/v1/N19-1407. URL <https://aclanthology.org/N19-1407/>.
- [76] Yuxin Wu and Kaiming He. Group normalization. In *Proceedings of the European conference on computer vision (ECCV)*, pages 3–19, 2018.
- [77] M Jorge Cardoso, Wenqi Li, Richard Brown, Nic Ma, Eric Kerfoot, Yiheng Wang, Benjamin Murrey, Andriy Myronenko, Can Zhao, Dong Yang, et al. Monai: An open-source framework for deep learning in healthcare. *arXiv preprint arXiv:2211.02701*, 2022.

- [78] Jari Korhonen and Junyong You. Peak signal-to-noise ratio revisited: Is simple beautiful? In *2012 Fourth international workshop on quality of multimedia experience*, pages 37–38. IEEE, 2012.
- [79] Zhou Wang, A.C. Bovik, H.R. Sheikh, and E.P. Simoncelli. Image quality assessment: from error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4):600–612, 2004. doi:[10.1109/TIP.2003.819861](https://doi.org/10.1109/TIP.2003.819861).