

Medical Flow Matching CT Translation

Крейнин Матвей

Московский физико-технический институт
Кафедра интеллектуальных систем

Научный руководитель: к.ф.-м.н. А.В. Грабовой
2025

- **Цель:** решается проблема трансляции модальности между сериями КТ изображений одного пациента.
- **Исследуемая проблема:** Диффузионные модель для КТ изображений требует огромные вычислительные ресурсы. Возможность направлять процесс трансляции только в одну сторону.
- **Метод решения:** Аппроксимация векторного поля между двумя распределениями π_0 и π_1 . Предложен метод инъекции временных в эмбедингов в блок нейронной сети.

Flow Matching

Постановка задачи

Даны распределения π_0 (источник) и π_1 (цель) в $\mathbb{R}^d$. Найти векторное поле $v_\theta : \mathbb{R}^{512 \times 512} \times [0, 1] \rightarrow \mathbb{R}^{512 \times 512}$, такое что решение ОДУ

$$\frac{dX_t}{dt} = v_\theta(X_t, t), \quad X_0 \sim \pi_0,$$

переносит π_0 в π_1 при $t = 1$.

Путь

Линейная траектория

$$X_t = (1 - t)X_0 + tX_1, \quad (X_0, X_1) \sim \pi_0 \times \pi_1.$$

Тогда таргетное поле постоянно:

$$v^*(x, t) = X_1 - X_0 \quad (\text{не зависит от } t).$$

Функция потерь

Обучаем v_θ аппроксимировать v_{target} в среднем по промежуточным скоростям:

$$\mathcal{L}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0,1]} \mathbb{E}_{X_0, X_1 \sim \pi_0 \times \pi_1} [\|v_\theta(X_t, t) - v^*\|^2]$$


$$\theta^* = \arg \min_{\theta} \mathcal{L}(\theta)$$

Трансляция


Объект из π_0 и численно интегрируем $\dot{X}_t = v_\theta(X_t, t)$ от $t = 0$ до $t = 1$.
Объект из π_1 и численно интегрируем $\dot{X}_t = v_\theta(X_t, t)$ от $t = 1$ до $t = 0$.

Схема метода


FlowMatching



TimeResNet



TimeResNetBlock



Постановка эксперимента

- 1 Дана выборка k объектов

$$\mathcal{D} = \{x_{0i}, x_{1i}\}, \quad x_{0i}, x_{1i} \in \pi_0 \times \pi_1, i = 1, \dots, k,$$

где x_i, y_i – аксиальных срезы Нативного и Контрастного изображения пациента. 120 исследований (52561 изображений), 80 (34992) - обучение, 20 (8197) - тестовая, 20 (9372) - валидационная.

- 2 Дополнительно проводится регистрация изображений с контрастом на нативное для уменьшения шума, связанного с движениями пациента, проводится локализация объекта исследования с помощью сегментационной модели для устранения артефактов.
- 3 Решается задача оптимизации

$$\theta^* = \arg \min_{\theta \in \Theta} \mathcal{L}(X, \theta),$$


где Θ – пространство нейросетей и предложенной архитектуры: TimeResNet, DiffusionNet, SwinUNETR, UNet, SegResNet.

Численные результаты

Model	MAE↓	SSIM↑	PSNR↑	Time, s↓	Params, M↓
TimeResNet (ours)	5.436	0.996	<u>39.776</u>	0.209	124.7
SwinUNETR	6.229	<u>0.992</u>	38.933	<u>0.087</u>	<u>120.1</u>
SegResNet	<u>6.146</u>	0.983	40.108	0.056	214.1
DiffusionNet	18.203	0.934	30.051	44.200	108.4
Smile (SOTA)	30.303	0.892	26.757	6.702	—

Таблица: Сравнение метрик моделей на hold-out выборке. TimeResNet и SwinUNETR обучены на задаче Flow Matching, SegResNet обучен на задачу регрессии, DiffusionNet обучен на задачу диффузии.

Визуальная демонстрация



- 1 Статистически значимые эксперименты, которые демонстрируют преимущество предложенного метода и архитектуры.
- 2 Проведено сравнение с наилучшей моделью и методом доступном в публичном доступе SMILE.
- 3 На задаче сегментации, nnUNetV2 на синтетически переведенных изображениях достигает Dice score = 0.926 против Dice score = 0.966 на реальных данных.
- 4 **Перспективы:** обусловленная генерация образований и патологий в органах.

- Предложен алгоритм инъекции времени в ResNet block.
- Построены SOTA архитектура TimeResNet.
- Статистически значимые эксперименты, которые демонстрируют преимущество предложенного метода и архитектуры.
- Получена скорость трансляции **400×** превышающая диффузионных моделей, качество значительно превышает регрессию.
- Возможность трансляции изображения в обе стороны со значимыми результатами.