

Flow Matching для трансляции КТ изображений

М. В. Крейнин, А. В. Грабовой

Московский физико-технический институт
Факультет управления и прикладной математики

Москва
2026 г

Цель

Разработка метода и архитектуры нейронной сети для быстрой двунаправленной трансляции между нативными и контрастными КТ сериями.

Проблема

Диффузионные модели требуют сотни шагов сэмплирования. Существующие методы допускают трансляцию только в одну сторону.

Предлагаемое решение

Фреймворк **Medical Flow Matching (MFM)** с архитектурой **TimeResNet**: инъекция временного параметра в каждый блок и свёрточный self-attention в узком горлышке.

Определения и Conditional Flow Matching

Определение (Пространство КТ срезов и поток)

$\mathcal{X} = [-1, 1]^{H \times W}$ — нормализованные КТ срезы; π_N, π_C — распределения нативных и контрастных серий; $\mathcal{D} = \{(\mathbf{x}_N^{(i)}, \mathbf{x}_C^{(i)})\}_{i=1}^n$. Векторное поле $f_\theta : \mathcal{X} \times [0, 1] \rightarrow \mathbb{R}^{H \times W}$ задаёт поток $\varphi_t: d\mathbf{x}_t/dt = f_\theta(\mathbf{x}_t, t)$, $\varphi_{1\#}\pi_N = \pi_C$.

Линейный интерполянт и функция потерь


Для $(\mathbf{x}_0, \mathbf{x}_1) \sim \pi_N \times \pi_C$: $\mathbf{x}_t = (1 - t)\mathbf{x}_0 + t\mathbf{x}_1$, $\mathbf{v}^* = \mathbf{x}_1 - \mathbf{x}_0$.

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{t \sim \mathcal{U}[0,1]} \mathbb{E}_{(\mathbf{x}_0, \mathbf{x}_1) \sim \pi_N \times \pi_C} [\|f_\theta(\mathbf{x}_t, t) - \mathbf{v}^*\|_2^2], \quad \theta^* = \arg \min_{\theta} \mathcal{L}_{\text{FM}}(\theta).$$


Утверждение (Двунаправленность)

Для f_{θ^*} и любого $\mathbf{x} \in \mathcal{X}$: $\hat{\mathbf{x}}_C = \mathbf{x} + \int_0^1 f_{\theta^*}(\mathbf{x}_t, t) dt$, $\hat{\mathbf{x}}_N = \mathbf{x} + \int_1^0 f_{\theta^*}(\mathbf{x}_t, t) dt$ — одна сеть реализует оба отображения $\pi_N \leftrightarrow \pi_C$.

Схема метода Medical Flow Matching




Архитектура TimeResNet: обзор



U-Net encoder–decoder с двумя модификациями:

1. **Per-block time injection** — аффинная модуляция в *каждом* ResNet блоке.
2. **Self-attention** в узком горлышке на самом грубом разрешении.

Per-block time injection: формализация



Определение (Time injection)


Оператор $\mathcal{M}_l : \mathbb{R}^{C_l \times H_l \times W_l} \rightarrow \mathbb{R}^{C_l \times H_l \times W_l}$ в блоке $l = 1, \dots, L$:

$$\mathcal{M}_l(\mathbf{h}; t) = \mathbf{A}_l(t) \odot \mathbf{h} + \mathbf{B}_l(t),$$

$$(\mathbf{A}_l, \mathbf{B}_l) = W_l \cdot \text{MLP}(\gamma(t)) \in \mathbb{R}^{2C_l},$$

где $\gamma : [0, 1] \rightarrow \mathbb{R}^{d_{\text{emb}}}$ — синусоидальное кодирование, $W_l \in \mathbb{R}^{2C_l \times d_{\text{mlp}}}$ — обучаемая проекция блока l .

Self-Attention в узком горлышке: формализация



Определение (Self-attention)

Пусть $\mathbf{Z} \in \mathbb{R}^{C \times H' \times W'}$ — вход.

$$Q = W_Q * \mathbf{Z}, \quad K = W_K * \mathbf{Z}, \quad V = W_V * \mathbf{Z},$$

W_Q, W_K, W_V — свёртки 1×1 ,
 $N = H' \cdot W'$.

$$\text{Attn}(\mathbf{Z}) = \mathbf{Z} + V \cdot \text{softmax}\left(\frac{Q^T K}{\sqrt{C}}\right).$$

Сложность: $\mathcal{O}(N^2 C)$, $N = \frac{HW}{4^k} \ll HW$.

Свойства архитектуры TimeResNet

Утверждение (Сохранение временного сигнала)

При per-block injection:

$$\frac{\partial \mathcal{L}}{\partial t} = \sum_{l=1}^L \frac{\partial \mathcal{L}}{\partial \mathbf{h}_l} \cdot \frac{\partial \mathcal{M}_l(\mathbf{h}_l; t)}{\partial t} \neq 0, \quad \forall l = 1, \dots, L.$$

При input-level concatenation: $\partial \mathbf{h}_l / \partial t = 0$ для $l > 1$.

Утверждение (Вычислительная сложность self-attention)

Пусть k — глубина encoder, $N_{\text{bottle}} = HW/4^k$. Тогда:

$$\frac{\mathcal{O}(N_{\text{bottle}}^2 C)}{\mathcal{O}((HW)^2 C)} = \frac{1}{4^{2k}}.$$

При $k = 4$: сложность в $\approx 65\,000$ раз меньше full-resolution attention.

Постановка эксперимента и результаты: C $\rightarrow$ N (held-out)

Данные: 120 абдоминальных КТ (52 561 срез), 80/20/20, регистрация ANTs SyN, HU $[-1000, 1000] \rightarrow [-1, 1]$. **Обучение:** Adam, $\text{lr } 2 \cdot 10^{-5}$, 30 эпох, batch 2, $4 \times \text{RTX } 3090$.

Метод	Модель	MAE $\downarrow$	SSIM $\uparrow$	PSNR $\uparrow$	Time, c	Params, M
Регрессия	SegResNet	6.33 ± 1.03	$.982 \pm .007$	38.46 ± 1.70	0.055	214.1
	UMambaBot	6.37 ± 1.01	$.982 \pm .007$	38.30 ± 1.64	0.075	141.6
Диффузия SOTA	DDPM	18.20 ± 1.39	$.934 \pm .008$	30.05 ± 1.48	44.2	124.7
	SMILE	30.22 ± 4.95	$.887 \pm .026$	26.70 ± 1.33	9.03	1066
Flow Match.	SegResNet	7.23 ± 1.07	$.979 \pm .007$	38.45 ± 1.65	0.065	214.1
	TimeResNet	4.25 ± 1.09	$.994 \pm .007$	42.19 ± 1.67	0.125	124.7

$$\frac{\text{MAE}_{\text{SMILE}}}{\text{MAE}_{\text{TimeResNet}}} \approx 7.1, \quad \frac{T_{\text{DDPM}}}{T_{\text{TimeResNet}}} \approx 354.$$

Результаты: $N \rightarrow C$ и MAE по органам (held-out)

Утверждение (Двунаправленная трансляция без переобучения)

Пусть f_{θ^*} обучена на $\mathcal{L}_{FM}$ с симметричной выборкой пар. Тогда $f_{\theta^*} = \arg \min_f [\mathcal{L}_{FM}^{N \rightarrow C}(f) + \mathcal{L}_{FM}^{C \rightarrow N}(f)]$ — переобучение для обратного направления не требуется. На аорте при синтезе контраста MFM в **15×** точнее SMILE.

Нативное $\rightarrow$ контрастное

Модель	MAE↓	SSIM↑	PSNR↑
SMILE	21.70±4.26	.903±.019	29.28±1.53
SegResNet	6.82±0.82	.983±.004	37.82±1.46
SwinUNETR	7.36±0.78	.982±.004	37.52±1.32
TimeResNet	4.57±0.87	.996±.004	41.52±1.53

MAE по органам (HU)

Метод	Аорта	Почки	Печень	Подж.
$C \rightarrow N$				
SegResNet (reg.)	23.7	21.8	13.1	17.6
SMILE	168.5	96.5	97.1	92.2
MFM	16.9	16.4	9.8	12.7
$N \rightarrow C$				
SMILE	295.8	177.9	63.0	121.5
MFM	20.1	24.3	12.8	15.4

LPIPS, межосевая согласованность и сравнение с DDIM

TotalSeg-LPIPS (C → N)

Метод	2D-LPIPS↓	3D-LPIPS↓
SegResNet (reg.)	.158±.051	.012±.005
SMILE	.704±.144	.096±.044
MFM	.138±.053	.007±.004

SSIM по проекциям


Метод	Акс.	Кор.	Саг.	Δ ↓
SegResNet (reg.)	.974	.973	.974	.0003
SMILE	.852	.848	.847	.0047
MFM	.984	.985	.983	.0001

Сравнение с ускоренным сэмплером диффузии (C → N)

Метод	Шагов	MAE↓	SSIM↑	Время, с	к MFM
DDPM (полный)	1000	18.20±1.39	0.934	44.20	354× медл.
DDIM-50	50	21.07±1.61	0.815	5.03	40× медл.
MFM (Эйлер-1)	1	4.25±1.09	0.994	0.125	1×

Δ SSIM = 0.0001 + низкое 3D-LPIPS $\Rightarrow$ межосевая согласованность синтеза, несмотря на 2D-обработку.

Визуальное сравнение, ablation и downstream сегментация



Аксиальный, сагиттальный, коронарный срезы

+ карты абсолютных ошибок.

Ablation компонентов TimeResNet

Вариант	MAE↓	SSIM↑	PSNR↑
TimeResNet	4.25	.994	42.19
без self-attn.	5.96	.985	39.84
без time inj.	6.02	.987	39.96
без обоих	6.67	.981	38.52

self-attn. → +1.71 HU; time inj. → +1.77 HU.

Downstream: nnUNet v2, аорта

Обучение на	Dice↑
Реальные x_N	0.966
Синтетические $\hat{x}_N$	0.926

95.9% базы ⇒ синтез пригоден для downstream.

1. Фреймворк **Medical Flow Matching**: $\theta^* = \arg \min_{\theta} \mathcal{L}_{\text{FM}}(\theta)$ с линейным интерполянтom — математическая формализация задачи переноса меры $\pi_N \leftrightarrow \pi_C$.
2. **Утверждение о двунаправленности**: $f_{\theta^*} = \arg \min_f [\mathcal{L}_{\text{FM}}^{N \rightarrow C}(f) + \mathcal{L}_{\text{FM}}^{C \rightarrow N}(f)]$ — единственная сеть реализует оба направления без переобучения.
3. Архитектура **TimeResNet** с теоретически обоснованными компонентами:
 - **Сохранение временного сигнала**: при $\mathcal{M}_l(\mathbf{h}; t) = \mathbf{A}_l(t) \odot \mathbf{h} + \mathbf{B}_l(t)$ выполнено $\partial \mathcal{L} / \partial t \neq 0$ на всех глубинах $l = 1, \dots, L$;
 - **Сложность буттлнекового self-attention**: $\mathcal{O}(N_{\text{bottle}}^2 C)$, в 4^{2k} раз дешевле полноразмерного.
4. **Утверждение об одношаговом инференсе**: при линейном интерполянте ускорение траектории $C_2 = 0$, поэтому глобальная ошибка Эйлера $e_N \leq (\delta/L)(e^L - 1)$ определяется лишь качеством аппроксимации сетью.